

1 Sistemi a coda

1.1 Determinazione lunghezza ottima trama

Invece di trasmettere l'intero messaggio di lunghezza M in un unico blocco, lo suddivido in pacchetti. Tuttavia, la somma delle dimensioni dei pacchetti può superare M , poiché a ciascun pacchetto viene aggiunto un header di lunghezza fissa.

Lunghezza messaggio	M
Lunghezza max campo dati di un pacchetto (payload) - <i>incognita</i>	K_{max}
Overhead di trama (header)	V

$$\text{Bit trasmessi per messaggio} = M + \left\lceil \frac{M}{K_{max}} \right\rceil \cdot V$$


Oss: con $K_{max} \uparrow$ ho meno trame, meno overhead, meno processing dei nodi. Con $K_{max} \downarrow$ più efficienza controllo, errore minori, richieste di buffer, minor ritardo di accesso (effetto pipe-lining).

Ipotesi: ritardo di propagazione trascurabile, probabilità di perdita dei pacchetti nulla, nessuna coda nei nodi.

Ritardo di trasmissione su j canali in serie di uguale capacità $[s]$	T
Capacità dei canali $[bit/s]$	C
Ritardo di trasmissione misurato in $[bit]$	$T \cdot C$

$$T \cdot C = (K_{max} + V)(j - 1) + M + \left\lceil \frac{M}{K_{max}} \right\rceil \cdot V$$

① (bit) impiegato dal primo pacchetto per attraversare $j - 1$ canali ② (bit) di trasmissione dell'intero messaggio nell'ultimo canale



NB: l'unico parametro che cambia sulla rete é la lunghezza dei messaggi M .

$$E[T \cdot C] = (K_{max} + V)(j - 1) + E[M] + \left[\frac{E[M]}{K_{max}} + \frac{1}{2} \right] \cdot V$$

L'ultimo pacchetto è, in media, mezzo pieno (o mezzo vuoto), approssimazione ceil:

$$E \left[\left\lceil \frac{M}{K_{max}} \right\rceil \right] \approx E \left[\frac{M}{K_{max}} \right] + \frac{1}{2}$$

$$\frac{\partial E[T \cdot C]}{\partial K_{max}} = (j - 1) - \frac{E[M] \cdot V}{K_{max}^2} = 0 \Rightarrow K_{max} \cong \sqrt{\frac{E[M] \cdot V}{j - 1}}$$

1.2 Notazione di Kendall e parametri caratteristici di un sistema di coda

Per descrivere formalmente un sistema di *coda d'attesa* (queueing system) è necessario specificarne alcune caratteristiche fondamentali, che influenzano in modo determinante il comportamento stazionario e dinamico del sistema stesso. I parametri principali sono:

- **Distribuzione dei tempi di interarrivo:** specifica il comportamento del processo di arrivo. Può essere:
 - **M (Markoviano):** arrivi secondo un processo di Poisson, tempi inter-arrivo esponenziali;
 - **D (Deterministico):** arrivi a intervalli costanti;
 - **G (Generale):** distribuzione arbitraria, non necessariamente esponenziale o deterministica.
- **Distribuzione dei tempi di servizio:** analogamente ai tempi di arrivo, anche la durata del servizio può seguire una distribuzione **M**, **D** o **G**.
- **Numero di serventi (m):** rappresenta il numero di canali di servizio paralleli (es. sportelli, server, macchine).
- **Capacità del sistema (C):** indica la massima quantità di utenti (in attesa + in servizio) che il sistema può contenere. Se un nuovo utente arriva quando il sistema è pieno, esso viene rifiutato o perso.
- **Popolazione sorgente (N):** dimensione della popolazione da cui provengono gli utenti. Se $N = \infty$, il tasso di arrivo è indipendente dallo stato del sistema. Se $N < \infty$, il tasso di arrivo può dipendere dal numero di utenti attualmente nel sistema.
- **Disciplina di servizio:** definisce l'ordine con cui i clienti vengono serviti. Le più comuni sono:
 - **FIFO (First In, First Out):** ordine di arrivo;
 - **LIFO (Last In, First Out):** ultimo arrivato viene servito per primo;
 - **Priorità:** i clienti sono divisi in classi con precedenza diverse.


Per sintetizzare queste caratteristiche, si utilizza la **notazione di Kendall**, che ha la forma estesa:

$$X|Y|m|C|N$$

dove:

- **X** indica la distribuzione dei tempi di interarrivo;
- **Y** indica la distribuzione dei tempi di servizio;
- **m** è il numero di serventi;
- **C** é la capacità della fila d'attesa (default ∞);
- **N** è la dimensione della popolazione sorgente (default ∞).

Esempio: La notazione $M|M|1$ rappresenta una coda con arrivi e servizi esponenziali (processo di Poisson), un solo servente, capacità illimitata e popolazione infinita. La notazione può essere abbreviata se $C = \infty$ e $N = \infty$, in tal caso si scrive semplicemente $X|Y|m$.



1.3 Distribuzioni

- **Distribuzione di Poisson:** la probabilità che si verifichino esattamente n arrivi nell'intervallo di tempo $(0, t)$ è data dalla formula:

$$P[n \text{ arrivi in } (0, t)] = P(n, t) = \frac{(\lambda t)^n}{n!} e^{-\lambda t}, \quad \text{per } n = 0, 1, 2, \dots$$

Se si considera un intervallo unitario ($t = 1$), la distribuzione diventa:

$$P[n \text{ arrivi nell'unità di tempo}] = P(n) = \frac{\lambda^n}{n!} e^{-\lambda}, \quad n = 0, 1, 2, \dots$$

dove λ è la frequenza media di arrivi per unità di tempo.

- **Distribuzione Esponenziale:** il tempo tra due arrivi consecutivi (inter-arrivo) è una variabile aleatoria esponenziale T con parametro $\lambda > 0$:

$$P(T > t) = P(0, t) = e^{-\lambda t}, \quad \text{ovvero } P(\text{nessun arrivo in } 0, t)$$

$$F_T(t) \equiv P(T \leq t) = 1 - P(T > t) = 1 - e^{-\lambda t} \quad \text{derivando ottengo:}$$

$$\text{ddp: } f_T(t) = \lambda e^{-\lambda t}, \quad t \geq 0$$

Il **processo non ha memoria**: il tempo residuo ha la stessa distribuzione dell'attesa iniziale. Anche se hai già atteso t_0 senza alcun arrivo, il tempo che ti resta da aspettare si comporta come se non fosse passato nulla. Considerando T una variabile aleatoria che rappresenta il tempo tra due eventi (cioè l'inter-arrivo) avremo che:

"La probabilità che il tempo fino al prossimo evento (ossia arrivo) sia maggiore di $t_0 + t$, dato che non è accaduto nulla fino al tempo t_0 , è uguale alla probabilità che il tempo fino al prossimo evento sia maggiore di t ."


$$P(T > t_0 + t \mid T > t_0) = P(T > t)$$

Osservazione importante: gli *inter-arrivi* in un processo di Poisson sono distribuiti esponenzialmente. Viceversa, se gli inter-arrivi sono esponenziali indipendenti, il processo è un processo di Poisson.

- **Distribuzione Erlangiana:** sia $X = T_1 + T_2 + \dots + T_n$, dove ciascun $T_i \sim \text{Exp}(\lambda)$. Allora X ha una distribuzione Erlangiana di ordine n , con densità:

$$f_X(x) = \frac{\lambda^n x^{n-1}}{(n-1)!} e^{-\lambda x}, \quad x \geq 0$$


Una v.a. Erlangiana di ordine n e media $\frac{1}{\lambda}$, può essere ottenuta come somma di n v.a. esponenziali con identico valor medio pari a $\frac{1}{n \cdot \lambda}$



- La **distribuzione iperesponenziale** è una combinazione pesata di più distribuzioni esponenziali, ed è utile per modellare tempi di attesa con alta variabilità (abbiamo probabilità α_i e velocità diverse λ_i).

Definizione: Una variabile T è iperesponenziale se ha densità:


$$f_T(t) = \sum_{i=1}^r \alpha_i \lambda_i e^{-\lambda_i t}, \quad \text{con } \sum_{i=1}^r \alpha_i = 1, \quad \alpha_i > 0, \quad \lambda_i > 0$$



1.4 Processi di Nascita e Morte


Definizioni:

- λ_i tempo di arrivo istantaneo (nascita)
- μ_i tempo di servizio istantaneo (morte)
- i il numero all'interno di ciascun stato indica il numero di utenti nel sistema.
- π_i o p_i probabilità stazionaria di trovarmi nello stato i .
- $p_{i,j}$ probabilità di transizione da stato i a j
- **equilibrio ai nodi:** *frequenza media ingresso = frequenza media uscita*



Teorema del bilancio su una superficie chiusa: per una qualunque *superficie chiusa* che circonda un gruppo di stati di una catena di Markov, il flusso medio **entrante** è identico al flusso medio **uscente**. Ciò permette di scrivere, “by inspection”, $N-1$ equazioni indipendenti in una catena con N stati. Il teorema vale sempre in **condizioni stazionarie**.

$$\begin{cases} \mu_1 p_1 = \lambda_0 p_0, & n = 0, \\ \lambda_{n-1} p_{n-1} + \mu_{n+1} p_{n+1} = (\lambda_n + \mu_n) p_n, & n \geq 1. \\ \sum_i p_i = 1 & N^o \text{ eq.} \end{cases}$$



$$\begin{cases} \mu \pi_1 = \lambda \pi_0 \\ \lambda \pi_1 = \mu \pi_2 \\ \pi_0 + \pi_1 + \pi_2 = 1 \end{cases}$$

1.5 Little's result



Il **Risultato di Little** è una formula molto utile nella teoria delle code. Mette in relazione tre quantità fondamentali di un sistema in **condizioni stazionarie** (il traffico accettato é uguale al traffico smaltito):

- λ : frequenza **media** ingressi, [utenti/secondo] (traffico accettato),
- N : il numero **medio** di utenti presenti nel sistema (coda + servizio),
- T : tempo di permanenza **medio** di un utente nel sistema (coda + servizio).

La relazione è la seguente:

$$N = \lambda \cdot T$$

Questo risultato è molto potente perché vale in generale, indipendentemente da :

- distribuzione delle lunghezze dei pacchetti
- distribuzione degli interarrivi
- metodi di instradamento

NB: posso applicare tale teorema sia sul sistema sia sui serventi.

1.6 Variabili fondamentali in un sistema di code

Per descrivere il comportamento di un sistema di coda si introducono le seguenti variabili:

- n : numero di utenti presenti nel sistema (in coda + in servizio);
- l : numero di utenti in attesa nella coda;
- h : numero di utenti attualmente in servizio;
- t : tempo totale trascorso da un utente nel sistema (coda + servizio);
- w : tempo di attesa in coda;
- ϑ : tempo di servizio (permanenza presso il servente);
- m : numero di serventi disponibili;
- c : capacità totale del sistema (utenti massimi ammessi, coda + servizio);

- $p_n = \Pr\{n \text{ utenti nel sistema}\}$: prob. stazionaria di avere n utenti nel sistema.
- λ_n : frequenza istantanea di arrivo nello stato n (n utenti nel sistema)
- μ_n : frequenza istantanea di uscita dal servizio nello stato n (n utenti nel sistema)
- p_c : probabilità di blocco (coda + servizi saturi = c)
- $\rho = 1 - p_0$: fattore di utilizzo del sistema

- $\Lambda = \lambda_1 + \lambda_2 + \dots$ (n flussi di traffico in ingresso): freq. media del traffico offerto
- T : tempo medio di permanenza nel sistema (coda + servizio)
- $N = \bar{n}$: numero medio di utenti nel sistema
- W : tempo medio attesa in coda

Si ha naturalmente:

$$n = l + h, \quad t = w + \vartheta.$$

Valori attesi Indicando con p_i la probabilità di avere i utenti nel sistema, i seguenti valori attesi risultano utili per la caratterizzazione del sistema:

$$\bar{n} = \mathbb{E}[n] = \sum_{i=0}^c i p_i$$

$$\bar{l} = \mathbb{E}[l] = \sum_{i=m+1}^c (i - m) p_i$$

$$\bar{h} = \mathbb{E}[h] = \sum_{i=0}^m i p_i + \sum_{i=m+1}^c m p_i = \bar{n} - \bar{l}$$

1.7 Nozioni teoriche

- **Stato di blocco:** si verifica quando il numero totale di utenti nel sistema, dato da $n = l + m$, raggiunge la capacità massima C (con $C < \infty$). In questo caso, eventuali nuove richieste vengono rifiutate: il sistema è detto **a perdita**.

- **Sistema con capacità illimitata:** se $C = \infty$, tutte le richieste vengono sempre accettate, indipendentemente dal numero di utenti già presenti - il sistema dispone di una coda illimitata.

- **Sistema stazionario:** il sistema è in stato stazionario quando le probabilità degli stati non cambiano nel tempo, e quindi anche tutte le grandezze statistiche (numero medio di utenti, tempi d'attesa, traffico smaltito, ecc.) si stabilizzano. In questo stato:

$$\lambda_S = \lambda_a \leq \lambda_o$$

dove: λ_o è il traffico offerto (quanto traffico arriva dall'esterno), λ_a è il traffico accettato (quanto traffico entra nel sistema), λ_S è il traffico smaltito (quanto traffico esce), $\lambda_r = \lambda_o - \lambda_a$ è il traffico eventualmente rifiutato. Questo è tipico nei sistemi a perdita con capacità finita ($C < \infty$).

- **Condizione di equilibrio:** un sistema con coda illimitata ($C = \infty$) è in equilibrio se e solo se il traffico offerto è inferiore alla capacità di servizio, ovvero:

$$\lambda_o < \mu, \quad \rho = \frac{\lambda}{\mu} < 1$$

In caso contrario, il numero di utenti nel sistema tenderebbe a crescere indefinitamente (accumulo infinito). Nel caso invece $C = k$, coda finita, il sistema risulta essere **sempre in equilibrio**.

- **Rapporto tra equilibrio e stazionarietà:** l'equilibrio è una condizione necessaria affinché il sistema possa diventare stazionario, ma non è sufficiente da sola. Se il sistema è in equilibrio, allora può raggiungere uno stato stazionario. Se non è in equilibrio, il sistema non può essere stazionario (le grandezze medie crescono nel tempo).

- **Teorema di Burke:** in un sistema $M|M|m$ in regime stazionario, il processo delle uscite è un processo di Poisson con lo stesso tasso degli arrivi. Questo risultato è particolarmente utile nelle reti di code, dove i processi di uscita diventano ingressi per altri nodi.

Anche se all'interno del singolo nodo si genera una correlazione tra arrivi e uscite (ad esempio, a causa della coda o della variabilità del servizio), in una rete realistica con molti nodi, router e collegamenti questi processi si sovrappongono, si mescolano e, nel tempo, tendono a diventare statisticamente scorrelati.

- Il **fattore di utilizzo del servente** indica per quanta parte del tempo il servente è occupato a lavorare rispetto al tempo totale disponibile.

$$\rho = \frac{\mathbb{E}[\text{busy period}]}{\mathbb{E}[\text{busy period} + \text{idle period}]}$$

- Posso applicare il teorema di Little sia sul sistema (coda + servizio) e in maniera separata solamente sul servizio (solo in condizioni stazionarie).

- Lo stato del sistema i è completamente specificato dal numero di utenti nel sistema (coda + servizio). Dove p_k indica la probabilità stazionaria di avere k utenti nel sistema.

$$i = 0, \dots, C$$

- **Osservazione:** nelle reti di telecomunicazione è meglio avere un unico server veloce piuttosto che tanti server lenti in parallelo, perché così si sfruttano meglio le risorse e si riducono i tempi morti.

- In un processo di Poisson le probabilità di arrivo sono indipendenti se gli intervalli I non sono sovrapposti $\Rightarrow$ la frequenza degli arrivi λ_n è costante e indipendente dallo stato del sistema: il processo degli arrivi è un processo di Poisson.

- **Uscite in $M/M/m$ con serventi omogenei vs eterogenei.**

- *Serventi omogenei* (μ ciascuno). In stato n , dove n è il **numero totale di clienti nel sistema** (in servizio + in coda), sono attivi $k = \min\{n, m\}$ serventi con tempi $\text{Exp}(\mu)$ i.i.d.; il prossimo completamento è

$$T = \min\{T_1, \dots, T_k\}, \quad T_i \sim \text{Exp}(\mu) \text{ indep.}$$

quindi $\Pr[T > t]$ è la **probabilità che nessun servizio termini entro i prossimi t secondi**, dove T è il tempo fino al prossimo completamento; per k serventi indipendenti con tasso μ ciascuno vale:

$$\Pr[T > t] = \prod_{i=1}^k e^{-\mu t} = e^{-k\mu t} \Rightarrow T \sim \text{Exp}(k\mu).$$

Il **tasso di uscita** (death rate) dallo stato n è

$$\mu_n = \min\{n, m\} \mu.$$

Esempio $m = 2$: $1 \rightarrow 0$ a tasso μ , $2 \rightarrow 1$ a tasso 2μ .

- *Serventi eterogenei* (μ_1, μ_2). Se entrambi i serventi sono occupati, i tempi $T_1 \sim \text{Exp}(\mu_1)$ e $T_2 \sim \text{Exp}(\mu_2)$ (indipendenti) corrono in parallelo:

$$T = \min\{T_1, T_2\} \Rightarrow \Pr[T > t] = e^{-(\mu_1 + \mu_2)t}, \quad T \sim \text{Exp}(\mu_1 + \mu_2),$$

perciò la transizione $2 \rightarrow 1$ ha tasso $\mu_1 + \mu_2$. **Attenzione:** quando $n = 1$ il tasso di uscita dipende da quale servente è occupato (μ_1 oppure μ_2). Quindi la catena che traccia solo n è Markoviana *solo* nel caso omogeneo; nel caso eterogeneo va raffinata distinguendo gli stati:

$$(1_1) \xrightarrow{\mu_1} (0), \quad (1_2) \xrightarrow{\mu_2} (0), \quad (2) \xrightarrow{\mu_1} (1_2), \quad (2) \xrightarrow{\mu_2} (1_1),$$

con arrivi a tasso λ verso un servente libero. *Generalizzazione a m serventi eterogenei:* se in stato n sono occupati i serventi in un insieme B (con $|B| = \min\{n, m\}$), allora

$$\mu_n = \sum_{i \in B} \mu_i,$$

e la modellazione Markov richiede stati che identifichino quali serventi sono occupati quando $n < m$.

1.8 Modello $M|M|1|\infty$

Si consideri un sistema di coda con


- arrivi **Poisson** con tasso medio λ (frequenza media arrivi);
- tempi di servizio **esponenziali** con parametro μ (durata media del servizio $1/\mu$);
- un solo servente;
- capacità e popolazione sorgente illimitate (nessuna perdita).

distr. di Poisson: $P[n \text{ arrivi in } 0, t] = \frac{(\lambda t)^n}{n!} e^{-\lambda t}$

distr. Esponenziale: $P[\text{servizio duri } t, t + dt] = \mu \cdot e^{-\mu t} dt$

$C = \infty$ devo verificare che il sistema sia in equilibrio e dunque che: $\lambda < \mu$.

Impongo l'equilibrio ai nodi: freq. ingresso = freq. uscita




Indicatori di prestazione: dove $\rho = \frac{\lambda}{\mu}$

<i>Numero medio di utenti nel sistema</i>	$N = \sum_{n=0}^{\infty} n \cdot p_n = \frac{\rho}{1 - \rho},$
<i>Tempo medio nel sistema (coda + serv)</i>	$T = \frac{N}{\lambda} = \frac{1/\mu}{1 - \rho} = \frac{1}{\mu - \lambda}$
<i>Tempo medio di attesa in coda</i>	$W = T - \frac{1}{\mu} = \frac{\rho}{\mu(1 - \rho)}.$

Osservazioni:

- Il traffico offerto λ_o è uguale al traffico accettato λ_a , non ho perdita. Tutto il traffico viene accettato, perché ho $C = \infty$.


1.9 Modello $M|M|1|C$



$$\lambda_n = \begin{cases} \lambda & n < C \\ 0 & n \geq C \end{cases} \quad \mu_n = \mu, \quad n = 1, \dots, C$$

Osservazioni:

- C indica il numero massimo utenti nel sistema (coda + servente)
- C è finito dunque il sistema risulta essere sempre in equilibrio.
- Il processo degli arrivi è indipendente dallo stato del sistema, ossia il processo di Poisson non interessa quale sia lo stato attuale, dunque avremo sempre un arrivo con frequenza λ .
- Esistenza di traffico rifiutato e abbiamo anche uno stato bloccante
- Il $\lambda_0 = \lambda_a$ fino a quando non ci troviamo in uno stato di blocco




Fattore di utilizzo del sistema $= 1 - p_0$

Traffico rifiutato: $\lambda_r = \lambda \cdot p_C$

Traffico accettato: $\lambda_a = \lambda - \lambda_r$

Prob. di blocco del sistema: p_C


1.10 Modello $M|M|1|\infty|M$ con popolazione finita



$$\lambda_n = \begin{cases} (M-n)\gamma & 0 \leq n \leq M \\ 0 & \text{altrimenti} \end{cases} \quad \mu_n = \mu, \quad 1 \leq n \leq M$$

Osservazioni:

- In questo modello, M rappresenta la **popolazione totale** (finita) di utenti potenzialmente attivi. Non ha alcun legame con la notazione markoviana standard.
- γ rappresenta il tasso medio con cui un singolo utente, attualmente fuori dal sistema, genera una nuova richiesta di ingresso.
- Il processo degli arrivi non è di Poisson, poiché il tasso λ_n dipende dallo stato del sistema. Questo rompe l'ipotesi di indipendenza temporale tra gli arrivi.
- La probabilità di un arrivo dipende quindi dinamicamente da quanti utenti sono **attualmente occupati nel sistema**. Ad esempio, se il sistema è nello stato k , il tasso di arrivo sarà $(M-k)\gamma$.
- Il numero massimo di utenti presenti contemporaneamente nel sistema è M , ma la coda è tecnicamente **illimitata**, perché non c'è una capacità massima imposta oltre al vincolo della popolazione.
- Nello stato M avremo che $\lambda_M = 0$ ossia non abbiamo arrivi.
- Traffico medio accettato = traffico medio offerto = traffico medio smaltito



Freq. media richieste di servizio: $\Lambda = \gamma(M - \bar{n}) = \mu(1 - p_0)$


Little's result: $T = \frac{\bar{n}}{\Lambda}$

1.11 Modello $M|M|1|\infty$ con arrivi scoraggiati

$$\begin{cases} \lambda_n = \frac{\lambda}{n+1} \\ \mu_n = \mu \end{cases} \quad \text{utente entra nel sistema con prob. } \frac{1}{n+1}$$

Osservazioni:

- $C = \infty$ bisogna verificare che $\Lambda = \bar{\lambda} < \mu$
- $C = \infty \Rightarrow \lambda_o = \bar{\lambda}_a = \bar{\lambda}_S$




1.12 Modello $M|M|\infty$

$$\begin{cases} \lambda_n = \lambda & n \geq 0 \\ \mu_n = n \cdot \mu & n \geq 1 \end{cases}$$

Osservazioni:

- La frequenza degli arrivi λ_n è costante e indipendente dallo stato del sistema: il processo degli arrivi è un processo di Poisson.
- La frequenza di servizio totale μ_n cresce linearmente con il numero di utenti n : ogni utente ha un servente dedicato, quindi non ci sono code (utenti serviti in parallelo).
- Non esiste limite alla capacità del sistema: può accettare un numero arbitrario di utenti contemporaneamente (capacità infinita).
- **Il sistema è sempre in equilibrio**, poiché non si ha mai accumulo: la crescita della capacità di servizio segue il numero di utenti.
- Nel modello $M|M|\infty$, ogni utente viene servito in parallelo da un proprio servente con tempo di servizio esponenziale di parametro μ . Le uscite avvengono una alla volta: dallo stato n si passa a $n-1$ perché i tempi di servizio sono variabili aleatorie indipendenti e la probabilità che due utenti completino il servizio esattamente nello stesso istante è nulla.




$$\begin{cases} p_a = p_0 \prod_{i=1}^{a-1} \frac{\lambda}{(i+1)\mu} = p_0 \left(\frac{\lambda}{\mu}\right)^n \frac{1}{n!} & \text{Poisson di parametro } \frac{\lambda}{\mu} \\ p_0 = e^{-\lambda/\mu} \end{cases}$$


Numero utenti medi nel sistema: $\bar{n} = \frac{\lambda}{\mu}$

Little's Result: $T = \frac{\bar{n}}{\lambda}$

1.13 Modello $M|M|m|0$




$$\lambda_n = \begin{cases} \lambda & n < m \\ 0 & n \geq m \end{cases} \quad \mu_n = n \cdot \mu, \quad n = 1, \dots, m$$




Prob. di blocco: $p_C = p_m$

1.14 Modello $M|E_k|1|\infty$




Osservazioni:

- Definiamo uno stato bidimensionale (n, i) , n numero utenti nel sistema, i stadio in cui si trova l'utente che è attualmente nel servizio
- Un tempo di servizio Erlangiano di ordine k è la somma di k fasi esponenziali indipendenti con lo stesso parametro. Ciò implica che il tempo medio in ciascuna fase è $\frac{1}{k\mu}$, in modo che il tempo medio totale sia $\frac{1}{\mu}$.
- Il passaggio da uno stadio all'altro avviene con tasso $k\mu$, così da mantenere il tempo medio totale invariato rispetto a un servizio esponenziale con tasso μ .
- In ogni stadio ci può essere un arrivo con frequenza λ , perché gli arrivi sono indipendenti dallo stato in cui ci troviamo
- Quando un utente entra nel servizio, nessun altro può entrare



1.15 Modello $M|H_2|1|0$




Osservazioni:

- Quando un utente è in servizio, nessun altro può entrare nel sistema.
- La distribuzione iperesponenziale H_2 è la somma pesata di due distribuzioni esponenziali:

$$f(t) = \sum_{i=1}^2 \alpha_i \lambda_i e^{-\lambda_i t}, \quad \sum_{i=1}^2 \alpha_i = 1$$

- Il parametro α_i rappresenta la probabilità che il tempo di servizio segua l'esponenziale con parametro μ_i .
- Questo modello può rappresentare scenari in cui esistono due tipi di clienti con diversi tempi medi di servizio.




Probabilità di blocco del sistema: $p_C = p_1 + p_2$

2 Reti di Code

- **Reti di code:** sistemi formati da più risorse o punti di servizio, ciascuno con una propria coda, in cui ogni stazione lavora in modo indipendente dalle altre (asincrono) e può funzionare contemporaneamente alle altre (concorrente). I clienti si spostano tra le stazioni secondo determinate regole, e se una risorsa è occupata devono attendere in coda prima di essere serviti.
- Una rete è composta da M stazioni di servizio (ogni nodo può avere più serventi) ognuna con la propria coda.

2.1 Modello del singolo sistema

Consideriamo un nodo i di una rete di code. Il nodo riceve traffico sia dall'esterno sia da altri nodi della rete, ed invia traffico verso altri nodi o verso la destinazione finale.



Estraggo dalla rete il canale i-esimo

- **Flussi in ingresso al nodo i :**
 - $q_{si} \lambda$: traffico *entrante dall'esterno* verso il nodo i .
 - $q_{ki} \lambda_k$: traffico proveniente da un nodo k della rete verso il nodo i .
- **Flussi in uscita dal nodo i :**
 - $q_{id} \lambda_i$: frazione di traffico in uscita che va direttamente verso la destinazione.
 - $q_{ij} \lambda_i$: frazione di traffico in uscita che va verso un altro nodo j della rete.

Osservazioni:

- La variabile λ_i rappresenta il **tasso medio di arrivo complessivo** al nodo i (in pacchetti/secondo o clienti/secondo), mentre μ_i è il **tasso di servizio** del nodo i .
- **Proprietà importante:** se i flussi entranti sono processi di Poisson (indipendenti), anche il traffico risultante al nodo i è un processo di Poisson, con tasso medio pari alla *somma* dei tassi medi dei singoli flussi
- **Il routing è probabilistico:** al termine del servizio in un nodo i , ogni cliente viene instradato verso la destinazione finale con probabilità q_{id} o verso un altro nodo j con probabilità q_{ij} , con $q_{id} + \sum_j q_{ij} = 1$. In pratica, è come tirare un dado per decidere la destinazione, e il traffico complessivo si può vedere come un insieme di flussi frazionati tra le varie uscite.

- Se la ripartizione del traffico in uscita dal nodo i avviene in modo **casuale**, con q_{ij} pari alla probabilità di instradare verso il nodo j , allora i flussi uscenti sono anch'essi processi di Poisson, con tasso medio $q_{ij} \lambda_i$.
- Se invece la ripartizione è **deterministica** (ad esempio ruotando ciclicamente tra u uscite), il traffico in ciascuna uscita non è più di Poisson: gli interarrivi hanno distribuzione *erlangiana* di ordine u con valor medio μ/λ_i .

2.2 Teorema di Burke

- In un sistema $M|M|1$, $M|M|m$ o $M|M|\infty$, con qualunque disciplina di coda e in regime stazionario, se il tasso medio degli arrivi è λ , allora:

Il processo in uscita è ancora di Poisson con tasso medio λ .

- **Esempio – Cascata di code:** l'ingresso di ogni coda coincide con l'uscita della precedente, quindi se la prima ha un'uscita di Poisson a tasso λ , anche le successive la riceveranno come processo di Poisson con lo stesso tasso.
- **Osservazione:** i tempi di attraversamento di nodi diversi non sono, in generale, indipendenti (ad esempio un messaggio lungo richiede tempi lunghi in tutte le code che attraversa), ma il teorema garantisce comunque la natura Poissoniana del flusso medio.

2.3 Reti di Jackson

Una rete di Jackson è un particolare tipo di rete di code con M nodi (o *canali*) che soddisfa le seguenti condizioni:

- Il servente al nodo i ha velocità di servizio $\mu_i(n)$ quando sono presenti n utenti nel nodo.
- Al completamento del servizio in un nodo, ogni utente sceglie la propria destinazione in modo **casuale e indipendente dal passato**: può uscire dalla rete oppure dirigersi verso un altro nodo.
- La rete è **aperta**, ossia può ricevere nuovi utenti dall'esterno.
- Gli arrivi esterni verso la rete avvengono secondo un **processo di Poisson**.

2.4 Teorema di Jackson

In una rete di Jackson, in stato stazionario, con tasso medio degli arrivi λ_i al nodo i , valgono le seguenti proprietà:

1. Il numero di utenti presenti in ciascun nodo è **indipendente** dal numero di utenti negli altri nodi.
2. Ogni nodo i si comporta statisticamente come se fosse caricato da un traffico di Poisson con tasso medio λ_i .

3. La distribuzione di probabilità congiunta nello stato stazionario ha forma di prodotto:

$$p(\mathbf{n}) = p(n_1, n_2, \dots, n_M) = \prod_{i=1}^M p_i(n_i)$$

dove

$$p_i(n_i) = (1 - \rho_i) \rho_i^{n_i}, \quad \rho_i = \frac{\lambda_i}{\mu_i}, \quad n_i \geq 0$$

per il caso di nodi $M|M|1$ con $\rho_i < 1$.

2.5 Reti di Jackson: Commenti

- Le diverse code, pur essendo interconnesse e soggette alle equazioni di bilancio dei flussi, si comportano come se fossero **indipendenti**.
- Ogni coda si può modellare come un sistema $M|M|1$ indipendente, con l'interconnessione che influisce solo sui valori di $\rho_i = \frac{\lambda_i}{\mu_i}$.
- Gli stessi risultati si ottengono anche per:
 1. Sistemi $M|M|m$ (tempi di servizio dipendenti dallo stato della coda), grazie al Teorema di Burke.
 2. Qualsiasi rete aperta con arrivi di Poisson (qui è stato considerato il caso di una sola coppia sorgente-destinazione).
- **Osservazione importante:** si assume che i tempi di servizio siano indipendenti da nodo a nodo. In realtà, un pacchetto “lungo” in uscita da una coda tenderà ad avere un tempo di servizio “lungo” anche nella coda successiva. Tuttavia, se molti flussi indipendenti si mescolano all'ingresso di una coda, la somma dei traffici diventa sufficientemente casuale da soddisfare l'ipotesi di indipendenza. Questa approssimazione è nota come **Kleinrock independence approximation**.

2.6 Valutazione Prestazioni di una Rete di Code


G.o.S (detta anche Quality of Service, QoS): tempo medio T^* impiegato per andare dal nodo sorgente al nodo destinazione = media pesata dei ritardi fra tutte le coppie di nodi.

$$T^* = \sum_{i,j} \frac{\gamma_{ij} T_{ij}}{\gamma}$$

dove:

- γ_{ij} = frequenza media di pacchetti con sorgente i e destinazione j ;
- $\gamma = \sum_{i,j} \gamma_{ij}$ = traffico medio totale entrante nella rete;
- T_{ij} = ritardo medio tra la sorgente i e la destinazione j .
- Questo indicatore fornisce un **valore unico** che rappresenta il comportamento medio della rete nel suo complesso.

- **Nota:** utilizzando questa definizione, il calcolo richiede $O(M^2)$ operazioni, pari al numero di coppie sorgente–destinazione nel grafo della rete. Dunque si utilizza:



$$\gamma T^* = E[n] \quad \text{LITTLE's RESULT}$$

$$E[n] = \sum_{i=1}^M E[n_i] \quad M = \text{numero lati/archi del grafo}$$

$$E[n_i] = \text{numero medio di messaggi in coda o in servizio sul nodo } i$$

$$= \lambda_i \cdot T_i = \lambda_i \cdot \frac{1}{\mu_i - \lambda_i}$$

$$T^* = \frac{1}{\gamma} \cdot \sum_{i=1}^M \lambda_i \cdot T_i = \frac{1}{\gamma} \cdot \sum_{i=1}^M \frac{\lambda_i}{\mu_i - \lambda_i}$$

in tal modo il calcolo del G.o.S ha complessità $O(M)$, ove 3 è il numero di lati del grafo

2.7 Note importanti

- In questo modello, ogni collegamento della rete è trattato come un sistema $M|M|1$, dove il tasso di servizio μ coincide con la capacità del link espressa in pacchetti al secondo: **trasmettere un pacchetto equivale a servirlo**, quindi μ rappresenta il numero massimo di pacchetti trasmessi nell'unità di tempo, mentre il tasso di arrivo λ è il traffico che deve attraversare quel link.
- In una rete di code, **ogni nodo** rappresenta una stazione di servizio (coda + servente) in cui i pacchetti attendono ed essere trasmessi o elaborati, mentre ogni link rappresenta il canale di comunicazione tra due nodi; in alcuni modelli semplificati, il link stesso è trattato come il servente con la coda immediatamente a monte.
- Il traffico totale che circola su tutti i link della rete (considerando entrambi i versi nei link full-duplex) è maggiore del traffico totale che entra nella rete, poiché ogni pacchetto, una volta entrato, percorre in media più di un link e quindi contribuisce al carico di più collegamenti.

$$\text{full duplex: } 2 \cdot \sum_i \lambda_i \geq \gamma$$

Traffico per coppia (sorgente, destinazione)	γ_{ABCD}
Velocità di trasmissione link pcks/s	μ
Traffico in pacchetti/s che attraversa il link AB	$\lambda_{AB} = \sum \gamma_{AB}$
Traffico totale su tutti i link	$\sum_i \lambda_i$
Traffico totale offerto (matrice R)	$\sum_{ij} R_{ij}$
Ritardo medio sul generico lato (MM1)	$E[T_i] = \frac{1}{\mu_i - \lambda_i}$
Numero di lati del grafo	M
Numero medio di pck ciascun link (sistema + coda)	n_i

$$\text{QoS: } T^* = \frac{1}{\gamma} \cdot \sum_{i=1}^M \lambda_i \cdot T_i = \frac{1}{\gamma} \cdot \sum_{i=1}^M n_i = \frac{1}{\gamma} \cdot \sum_{i=1}^M \frac{\lambda_i}{\mu_i - \lambda_i}$$

Numero medio link attraversati da un pacchetto:

$$\bar{n} = \frac{\text{traffico totale su tutti i link}}{\text{traffico entrante}} = \frac{2 \cdot \sum_i \lambda_i}{\gamma}$$

NB: trasformare tutto in pck/s per la risoluzione dell'esercizio.

3 Routing

Criteri di valutazione delle tecniche di instradamento

- **Throughput** (S): quantità media di traffico utile trasferito con successo (traffico smaltito), espressa in pacchetti/s o bit/s.
- **Ritardo medio** (T): tempo medio impiegato da un pacchetto per andare dalla sorgente alla destinazione.
- **Affidabilità** (A): probabilità che un pacchetto arrivi correttamente a destinazione.

La politica di instradamento rispettare	vincoli di fattibilità e solenoidalità
Capacità di rete	traffico massimo smaltito da una rete
	$C = \max_{intrad.} S(I, A)$
Class. tecniche di instradamento:	deterministiche o dinamiche

4 Simulazione dei sistemi di comunicazione

- Generazione di numeri pseudo-casuali: problema suddiviso in due parti
 - Generazione di sequenze di numeri uniformemente distribuiti tra 0 e 1
 - Generazione di sequenze di numeri distribuiti in modo arbitrario
- Partendo da una distribuzione uniforme si può derivare qualsiasi altra distribuzione nota tramite opportune trasformazioni matematiche, anche con sola conoscenza del grafico della distribuzione desiderata.

4.1 Generazione di numeri pseudo casuali

Generazione di una distribuzione arbitraria a partire dall’uniforme. Se si dispone di un generatore di numeri uniformi in $(0, 1)$, è possibile ottenere variabili casuali con distribuzione arbitraria applicando una trasformazione appropriata.

Teorema fondamentale delle funzioni di variabili aleatorie. Sia $Y = g(X)$, dove X è una variabile aleatoria continua con densità $f_X(x)$. La densità di Y è data da:

$$f_Y(y) = \sum_i \frac{f_X(x_i)}{|g'(x_i)|}$$

dove x_i sono le soluzioni dell’equazione $y = g(x)$.

Caso particolare: trasformazione tramite CDF. Sia X una variabile aleatoria con funzione di ripartizione (CDF) $F_X(x)$. Consideriamo:

$$Y = F_X(X), \quad 0 \leq y \leq 1$$

Quando fai la trasformazione $Y = F_X(X)$, stai prendendo l’uscita della CDF: qualunque sia X , il valore di Y sarà sempre compreso fra 0 e 1, dove y è una possibile realizzazione di Y . **Dal teorema precedente segue:**

$$f_Y(y) = \frac{F'_X(x_1)}{F'_X(x_1)} = 1, \quad 0 \leq y \leq 1$$

poiché $F'_X(x) = f_X(x)$.

Interpretazione. Applicando la CDF F_X ad una variabile casuale X otteniamo una variabile uniforme $U \sim U(0, 1)$. Viceversa, applicando l’inversa F_X^{-1} ad una variabile uniforme si ottiene una variabile con distribuzione F_X .

Metodo dell’inversa.

1. Generare $U \sim U(0, 1)$.
2. Calcolare $X = F_X^{-1}(U)$.
3. Allora X ha distribuzione con CDF F_X .

Idea chiave. La CDF $F_X(x)$ trasforma una variabile casuale arbitraria in una variabile uniforme; la funzione inversa F_X^{-1} trasforma una variabile uniforme in una variabile con la distribuzione desiderata.




Figura 1: Trasformazione diretta: $X \rightarrow F_X(X) \rightarrow U$




Figura 2: Metodo dell’inversa: $U \rightarrow F_X^{-1}(U) \rightarrow X$

Collegamento alla teoria. La quantità $P\{X \leq t\}$ è proprio la *funzione di distribuzione cumulativa* (Cumulative Distribution Function, CDF) della variabile X :

$$F_X(t) = P(X \leq t)$$

Essa rappresenta “quanto” della probabilità totale è accumulata fino al valore t .


Variabili aleatorie discrete. Una variabile aleatoria discreta è caratterizzata da un insieme di *valori possibili* finito o numerabile, ad esempio $\{0, 1, 2, 3\}$ oppure $\mathbb{N}$. È descritta dalla *funzione di massa di probabilità* (PMF) $p_X(x)$, che associa a ciascun valore x la probabilità:

$$p_X(x) = P(X = x)$$

Le proprietà fondamentali sono:

$$p_X(x) \geq 0 \quad \forall x, \quad \sum_x p_X(x) = 1$$

Il valore di $p_X(x)$ rappresenta la probabilità esatta che X assuma il valore x .





Variabili aleatorie continue. Una variabile aleatoria continua assume valori in un insieme *non numerabile*, tipicamente un intervallo di $\mathbb{R}$ (ad esempio $[a, b]$ oppure $(-\infty, +\infty)$). È descritta dalla *funzione di densità di probabilità* (PDF) $f_X(x)$, che soddisfa:

$$f_X(x) \geq 0 \quad \forall x, \quad \int_{-\infty}^{+\infty} f_X(x) dx = 1$$

Il valore di $f_X(x)$ non rappresenta una probabilità diretta, ma la *densità* di probabilità attorno a x . La probabilità che X assuma un valore compreso tra u e v è data da:

$$P(u \leq X \leq v) = \int_u^v f_X(x) dx$$



NB: per le variabili casuali discrete il concetto si complica.

4.2 Sintesi di una variabile aleatoria mediante il metodo del percentile

Per **sintesi di una variabile aleatoria** si intende la costruzione (o simulazione) di realizzazioni di una variabile casuale X con una certa distribuzione assegnata, a partire da numeri pseudo-casuali uniformi in $(0, 1)$. Mentre l'analisi statistica parte dai dati per stimarne le proprietà, la sintesi procede in senso inverso: dati i parametri della distribuzione, si generano campioni che la seguono.

Il **metodo del percentile** (o *inverse transform method*) si basa sull'uso della funzione di ripartizione $F_X(x)$ e della sua inversa $F_X^{-1}(\cdot)$:

- Si generi $U \sim \mathcal{U}(0, 1)$, cioè una variabile casuale uniforme nell'intervallo $(0, 1)$.

- Si ponga:

$$X = F_X^{-1}(U).$$

- Allora X è distribuita secondo la funzione di ripartizione $F_X(x)$.

Dimostrazione. Per ogni $t \in \mathbb{R}$:

$$P(X \leq t) = P(F_X^{-1}(U) \leq t) = P(U \leq F_X(t)) = F_X(t),$$

da cui segue che X ha effettivamente distribuzione F_X .

Osservazioni.

- La variabile U si ottiene dai generatori di numeri pseudo-casuali.
- Il metodo richiede la conoscenza (o la possibilità di calcolare) dell'inversa F_X^{-1} .
- Per variabili aleatorie discrete la costruzione va adattata, usando la funzione di ripartizione a gradini.

Esempio. Per una v.a. esponenziale con media $\lambda > 0$:

$$F_X(x) = 1 - e^{-x/\lambda}, \quad x \geq 0,$$

si ha

$$X = -\lambda \ln(1 - U) \sim \text{Exp}(\lambda).$$

4.3 Uso della CDF e metodo del percentile

Un punto fondamentale nella sintesi di variabili aleatorie è distinguere tra:

- Y : la **variabile aleatoria** (funzione che associa ad ogni esito $\omega \in \Omega$ un numero reale $Y(\omega)$);

$$Y: \Omega \rightarrow \mathbb{R}$$

- y : un **valore numerico** reale, cioè una possibile realizzazione di Y .

Funzione di ripartizione. La funzione di ripartizione (CDF) di Y è definita come

$$F_Y(y) = \mathbb{P}(Y \leq y), \quad y \in \mathbb{R}.$$

L'argomento è minuscolo perché si valuta la probabilità che la v.a. Y sia minore o uguale ad un numero fissato y .

Composizione con la CDF. Se invece scriviamo

$$U = F_Y(Y),$$

stiamo componendo due funzioni. In altre parole:

$$U(\omega) = F_Y(Y(\omega)).$$

Il risultato è una nuova variabile aleatoria U . Un teorema importante (*Probability Integral Transform*) stabilisce che, se F_Y è continua, allora

$$U = F_Y(Y) \sim \mathcal{U}(0, 1).$$

Metodo del percentile. Il ragionamento si inverte nel **metodo del percentile**: se $U \sim \mathcal{U}(0, 1)$, allora definendo

$$X = F_X^{-1}(U),$$

si ottiene una variabile aleatoria X distribuita secondo la CDF F_X .

Esempio. Se $Y \sim \text{Exp}(\lambda)$ con

$$F_Y(y) = 1 - e^{-y/\lambda}, \quad y \geq 0,$$

allora

$$U = F_Y(Y) = 1 - e^{-Y/\lambda} \sim \mathcal{U}(0, 1),$$

e invertendo si ha

$$Y = F_Y^{-1}(U) = -\lambda \ln(1 - U).$$

Conclusione.

- $F_Y(y)$ = probabilità che Y assuma valori $\leq y$ (argomento numerico).
- $F_Y(Y)$ = nuova v.a. costruita componendo la CDF con Y (risulta uniforme).
- Metodo del percentile: genera $U \sim \mathcal{U}(0, 1)$ e poni $X = F_X^{-1}(U)$ per sintetizzare X con CDF F_X .

4.4 Analisi e convalida dei risultati

- Dopo la costruzione del modello e del software di simulazione, occorre scegliere le variabili d'uscita da misurare, definirne i parametri statistici (media, varianza, percentili), **adottare opportuni stimatori** e **valutarne l'accuratezza tramite intervalli di confidenza**.
- Data una popolazione con distribuzione $f(x)$, media η e varianza σ^2 , la media campionaria di n osservazioni indipendenti $[x_1, x_2, \dots, x_n]$ è definita come:

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

ed è essa stessa una variabile casuale.

- La media campionaria $\bar{x}$, calcolata su n osservazioni indipendenti, è anch'essa una variabile casuale con media $E[\bar{x}] = \eta$ e varianza $\sigma^2(\bar{x}) = \frac{\sigma^2}{n}$. Quando n è grande, **grazie al Teorema Centrale del Limite**, la distribuzione di $\bar{x}$ si avvicina a una normale di media η e varianza $\frac{\sigma^2}{n}$. In questo caso, la variabile standardizzata

$$z = \frac{\bar{x} - \eta}{\sigma/\sqrt{n}}$$

segue approssimativamente una distribuzione normale standard, cioè con media $\mu = 0$ e varianza $\sigma^2 = 1$.

- **Che cos'è α e come entra nell'intervallo di confidenza.** Scegliamo un livello di *significatività* $0 < \alpha < 1$: è la **probabilità totale di non copertura** (errore di livello) che accettiamo per l'intervallo stimato; di conseguenza, il **livello di confidenza** è $1 - \alpha$. Nel caso bilatero, α si ripartisce simmetricamente nelle due code della normale standard, cioè $\frac{\alpha}{2}$ per coda. Poiché

$$z = \frac{\bar{x} - \eta}{\sigma/\sqrt{n}} \approx \mathcal{N}(0, 1),$$

indichiamo con F la CDF della normale standard e definiamo il *quantile* (percentile) centrale

$$F(u_{1-\frac{\alpha}{2}}) = 1 - \frac{\alpha}{2} \quad \implies \quad F(-u_{1-\frac{\alpha}{2}}) = \frac{\alpha}{2}.$$

Per simmetria segue che la probabilità di cadere tra i due quantili centrali è

$$P\left\{-u_{1-\frac{\alpha}{2}} \leq z \leq u_{1-\frac{\alpha}{2}}\right\} = 1 - \alpha.$$


Sostituendo z otteniamo

$$P\left\{-u_{1-\frac{\alpha}{2}} \leq \frac{\bar{x} - \eta}{\sigma/\sqrt{n}} \leq u_{1-\frac{\alpha}{2}}\right\} = 1 - \alpha,$$

da cui **l'intervallo di confidenza bilatero** (con σ nota):

$$P\left\{\bar{x} - u_{1-\frac{\alpha}{2}} \frac{\sigma}{\sqrt{n}} \leq \eta \leq \bar{x} + u_{1-\frac{\alpha}{2}} \frac{\sigma}{\sqrt{n}}\right\} = 1 - \alpha.$$

Lettura pratica: α lo fissi *a priori* (tipicamente 0.05 o 0.01): più piccolo è α , più ampio è l'intervallo ma maggiore è la confidenza (es.: $\alpha = 0.05 \Rightarrow u_{0.975} \approx 1.96$). Se σ è ignota, sostituisci σ con la deviazione standard campionaria s e $u_{1-\frac{\alpha}{2}}$ con il quantile $t_{1-\frac{\alpha}{2}, n-1}$ della t di Student. *Significato frequenzista:* l'intervallo è una regola casuale che, ripetendo campionamenti indipendenti, copre η nel $100(1-\alpha)\%$ dei casi.



- L'intervallo di confidenza bilatero al livello $1 - \alpha$ (con σ nota) è definito da

$$P\left\{\bar{x} - u_{1-\alpha/2} \frac{\sigma}{\sqrt{n}} \leq \eta \leq \bar{x} + u_{1-\alpha/2} \frac{\sigma}{\sqrt{n}}\right\} = 1 - \alpha.$$

La costante $(1 - \alpha)$, solitamente espressa in percentuale, è detta **livello di confidenza**, mentre l'intervallo

$$\left(\bar{x} - u_{1-\alpha/2} \frac{\sigma}{\sqrt{n}}, \bar{x} + u_{1-\alpha/2} \frac{\sigma}{\sqrt{n}}\right)$$

è detto **intervallo di confidenza**.

- Un livello di confidenza comunemente adottato è il 95%, per cui $\alpha = 0.05$ e $u_{1-\alpha/2} = 1.96$. In tal caso, l'intervallo di confidenza per η è

$$\left(\bar{x} - 1.96 \frac{\sigma}{\sqrt{n}}, \bar{x} + 1.96 \frac{\sigma}{\sqrt{n}}\right)$$

e indica che η cade in tale intervallo con probabilità del 95%.


- Quando la varianza della popolazione σ^2 non è nota, viene stimata tramite la varianza campionaria

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2.$$

In tal caso, la variabile standardizzata diventa

$$t = \frac{\bar{x} - \eta}{S/\sqrt{n}},$$

che non segue più la distribuzione normale ma la ***t di Student*** con $n - 1$ gradi di libertà. Per n grande (tipicamente $n > 30$), la distribuzione t di Student si approssima bene alla normale standard; per n piccoli è invece necessario utilizzare la t di Student con il numero di gradi di libertà appropriato. Nelle simulazioni Monte Carlo è frequente avere $n > 30$, mentre nelle simulazioni temporali n tende a essere più piccolo.



- Nel caso di due variabili aleatorie x e y , indichiamo i rispettivi intervalli di confidenza come

$$P\{x_l \leq x \leq x_u\} = 1 - \alpha_x, \quad P\{y_l \leq y \leq y_u\} = 1 - \alpha_y.$$

Se si applica una trasformazione lineare $Ax + B$ alla variabile x (con A e B costanti), l'intervallo di confidenza si trasforma linearmente nei limiti, senza modificarne la probabilità:

$$P\{Ax_l + B \leq Ax + B \leq Ax_u + B\} = 1 - \alpha_x.$$

Nel caso della differenza tra due variabili, l'incertezza complessiva aumenta poiché bisogna considerare entrambe le fonti di errore; infatti si ha:

$$P\{x_l - y_u \leq x - y \leq x_u - y_l\} \geq 1 - \alpha_x - \alpha_y.$$

Questo principio è utile quando, ad esempio, si misurano più grandezze (magari correlate) e si vogliono stimare intervalli per combinazioni lineari di esse. In sintesi:

- una trasformazione lineare di una singola variabile non modifica il livello di confidenza (cambia solo i limiti);
- per funzioni di più variabili, il livello di confidenza diminuisce, a meno di considerare intervalli più ampi per ciascuna variabile.

- La varianza della popolazione può essere stimata in modo diretto utilizzando l'identità

$$\sigma^2(x) = E[x^2] - (E[x])^2,$$

che lega la varianza alla differenza tra il valor medio del quadrato e il quadrato del valor medio. In pratica, si considerano due insiemi di osservazioni: la popolazione originaria $\{x_1, x_2, \dots, x_n\}$ e la popolazione dei quadrati $\{x_1^2, x_2^2, \dots, x_n^2\}$. Si calcolano quindi gli intervalli di confidenza per le medie di x e di x^2 separatamente, applicando le formule viste in precedenza (con σ nota o stimata e, se necessario, la distribuzione t di Student). Combinando opportunamente questi due intervalli tramite l'espressione sopra, si ottiene un intervallo di confidenza per σ^2 .

- Le procedure di stima fin qui discusse si basano su tre ipotesi fondamentali: (1) le variabili osservate sono **stazionarie** (media e varianza costanti nel tempo), (2) le misure non sono influenzate dallo stato iniziale (in pratica, si eliminano le prime N osservazioni per evitare effetti transitori), (3) le osservazioni sono **indipendenti** tra loro. Tra queste, l'ipotesi di indipendenza è la più difficile da verificare e rispettare nei casi reali, poiché l'indipendenza delle osservazioni dipende dalle **caratteristiche di correlazione** della variabile, che spesso non sono note. La violazione di questa condizione può portare a sottostimare l'incertezza e a intervalli di confidenza troppo ottimistici.
- Nel caso di **osservazioni correlate**, lo stimatore della media campionaria $\bar{x}$ rimane *non polarizzato* ($E[\bar{x}] = \eta$), ma la sua varianza non è più semplicemente σ^2/n . Essa diventa:

$$\sigma^2(\bar{x}) = \frac{\sigma^2}{n} \left[1 + 2 \sum_{k=1}^{n-1} \left(1 - \frac{k}{n} \right) \rho_k \right],$$

dove ρ_k è il **coefficiente di correlazione** al ritardo k , definito come

$$\rho_k = \frac{E[(x_i - \eta)(x_{i+k} - \eta)]}{\sigma^2}.$$

In presenza di autocorrelazione positiva ($\rho_k > 0$), la varianza di $\bar{x}$ aumenta rispetto al caso indipendente, portando a intervalli di confidenza più ampi; viceversa, correlazioni negative possono ridurla.

- In presenza di **osservazioni correlate**, la stima dell'intervallo di confidenza per la media richiede la conoscenza della **funzione di autocorrelazione** del processo, che in genere non è nota. Si potrebbe stimare tale funzione tramite appositi stimatori, ma ciò comporterebbe un'elevata complessità e un notevole carico computazionale. Per semplificare, si adottano comunemente due differenti approcci per ottenere **sequenze di osservazioni indipendenti**, riducendo così l'effetto dell'autocorrelazione e permettendo l'uso delle formule standard per la varianza e gli intervalli di confidenza. Alcuni di questi sono:
 - prove ripetute
 - suddivisione in intervalli di osservazione (run)

- **Primo approccio – prove ripetute:** si generano N osservazioni indipendenti del processo ripetendo N volte la simulazione, ciascuna con un diverso generatore di numeri casuali. I N valori stimati da ogni simulazione vengono trattati come campioni indipendenti per calcolare l'intervallo di confidenza. Questo metodo equivale a una **generalizzazione della simulazione Monte Carlo** ed è utile in molti contesti pratici, ma viene in genere impiegato solo quando il secondo metodo (più efficiente) non è applicabile.
- **Secondo approccio – suddivisione in intervalli di osservazione (run):** la simulazione viene suddivisa in N blocchi, ciascuno contenente un numero K di osservazioni. Si calcola la media della variabile d'uscita per ogni blocco e, scegliendo K sufficientemente grande, tali medie possono essere considerate indipendenti. L'intervallo di confidenza viene stimato a partire dalle medie ottenute nei singoli run. Questo metodo è di tipo approssimato e può risultare poco agevole se non è semplice garantire che il numero K di osservazioni sia identico per tutti i blocchi.

5 La Protezione nelle Reti di Telecomunicazione

Resilience in WDM Networks Nel contesto delle reti in fibra ottica, la **tecnologia WDM** (Wavelength Division Multiplexing) consente a un singolo cavo in fibra di trasportare enormi quantità di dati, nell'ordine dei terabit al secondo. Tuttavia, il guasto di un componente di rete può comportare gravi perdite sia di dati che di ricavi. Per prevenire tali conseguenze, si adottano meccanismi di **protezione**, ovvero procedure proattive per garantire la continuità del servizio in caso di guasto. In queste configurazioni, un **percorso primario** trasporta il traffico durante il normale funzionamento, mentre **risorse di backup aggiuntive** sono pre-riservate e vengono attivate automaticamente qualora il percorso primario fallisca.

Challenges L'operatore di rete si trova ad affrontare diverse sfide, tra cui la necessità di **soddisfare i requisiti di Qualità del Servizio (QoS)** stabiliti dal cliente tramite un **SLA** (Service Level Agreement). Una violazione dell'SLA può comportare il pagamento di una penale da parte dell'operatore. I livelli di servizio (Premium, Gold, Silver, Bronze) si differenziano per criteri di fuori servizio, tempo di ripristino con SLA degradato, tempo di recupero totale e disponibilità complessiva del servizio. Parallelamente, l'operatore deve selezionare uno schema di protezione che sia economicamente efficace per raggiungere tali obiettivi.

	Premium	Gold	Silver	Bronze
Out of service criterion	Degraded BER=10 ⁻⁴	Degraded BER=10 ⁻³	Fault (LOS)	Fault (LOS)
Recovery time with degraded SLA	Not spec.	50 ms	500 ms	5 sec
Full recovery time	50 ms	300 ms	5 sec	5 min
Service unavailability	10 ⁻⁵	10 ⁻⁴	10 ⁻³	10 ⁻²

Why do we protect? La protezione è normalmente implementata con lo **scopo di aumentare la disponibilità** della connessione end-to-end. La *availability* è definita come la frazione di tempo in cui la connessione è operativa durante l'intero periodo di servizio, espressa in minuti/anno:

$$Availability = \frac{Tempo\ disponibile}{Tempo\ disponibile + Tempo\ di\ inattività}.$$

L'adozione di meccanismi di protezione contribuisce ad aumentare la disponibilità, ad esempio instradando il traffico dal percorso primario guasto verso un percorso di backup. Maggiore è il numero di risorse di backup disponibili, maggiore sarà la disponibilità complessiva del sistema.

Availability (1) Ogni componente di rete è caratterizzato dalla propria *availability*, che dipende da due fattori principali:

- **Tasso di guasto** (*Failure rate*): espresso come *Mean Time To Failure* (MTTF) - valore atteso del tempo che un sistema (o componente) funziona senza guastarsi, pari a

$$MTTF = \frac{1}{\lambda}.$$

- **Tasso di ripristino** (*Failure recovery rate*): espresso come *Mean Time To Repair* (MTTR) - tempo medio necessario per riparare o ripristinare il sistema dopo un guasto, pari a

$$MTTR = \frac{1}{\mu}.$$

Le statistiche Bellcore riportano, ad esempio, un MTTR di 2 ore per l'equipaggiamento e di 12 ore per un taglio di cavo, con una frequenza media di taglio pari a 4.39/anno ogni 1000 miglia di guaina.

Path availability La disponibilità complessiva di un percorso (A_t) è calcolata come il prodotto delle disponibilità A_i dei N componenti che lo costituiscono:

$$A_t = \prod_{i=1}^N A_i$$

dove:

$$A_i = \frac{MTTF}{MTTR + MTTF}$$

Il principale motivo di guasto è legato ai collegamenti in fibra ottica.

First Conclusion Per raggiungere l'obiettivo delle 5 9's (99.999%) nelle connessioni a lunga distanza, è necessario proteggere il segnale. In letteratura esistono diversi schemi di protezione, ognuno con i propri vantaggi e svantaggi. I più comuni sono:


- **Dedicated Protection**
- **Shared Protection**

Non sempre è noto quale sia la disponibilità risultante per ciascun approccio; spesso si tende a combinare i vantaggi di entrambi per utilizzare le risorse in modo efficiente, soddisfacendo al contempo i requisiti dell'utente.


Dedicated Protection Nelle reti di telecomunicazione, la **protezione dedicata** prevede che ad ogni collegamento primario (working path) venga assegnato un collegamento di protezione (backup path) riservato esclusivamente a esso. In caso di guasto, il traffico viene instradato immediatamente sul percorso di backup. Questa strategia garantisce elevata disponibilità (availability) e tempi di ripristino molto rapidi, ma richiede un uso di risorse ridondanti pari al 100%. Le configurazioni più comuni sono:

- **1:1**: il percorso di protezione è predisposto ma normalmente inattivo; viene attivato solo in caso di guasto del primario.
- **1+1**: il traffico è trasmesso simultaneamente sia sul percorso primario che su quello di protezione; al ricevitore si seleziona in tempo reale il flusso corretto, garantendo tempi di ripristino praticamente nulli.

2:1 - 2 cammini di backup per un cammino primario



Shared Protection Nella configurazione *Shared Protection*, più cammini primari condividono lo stesso cammino di backup. In questo esempio, due cammini primari sono protetti da un unico percorso di riserva (1 : 2), ottimizzando l'uso delle risorse di rete. Questo approccio riduce i costi e la quantità di capacità di backup necessaria, ma può introdurre rischi di contesa qualora più guasti si verificassero simultaneamente sui cammini primari protetti.



Priority-Aware Shared Protection Questo schema combina i vantaggi della *Dedicated Protection* e della *Shared Protection*, introducendo una differenziazione dei servizi. Le connessioni vengono suddivise in due classi di priorità: N_G connessioni *Gold* e N_S connessioni *Silver*, che condividono lo stesso cammino di backup. **In caso di contesa**, le connessioni *Gold* possono preemptare quelle *Silver* nell'utilizzo delle risorse di backup, garantendo così livelli di servizio differenziati.


Analysis of 1:N Protection without Service Differentiation Si considerano N cammini operativi protetti da un unico cammino di protezione. Il sistema può essere modellato come una catena di Markov con $N + 1$ stati, dove lo stato i rappresenta il numero di cammini fuori servizio (inclusi quelli primari e di protezione). Il modello prevede le seguenti transizioni: da uno stato i a $i + 1$ con tasso $(N + 1 - i)\lambda$ e da i a $i - 1$ con tasso $i\mu$. La probabilità stazionaria è data da:

$$p(n) = \binom{N+1}{n} A^n A^{N+1-n} = \binom{N+1}{n} \left(\frac{\rho}{1+\rho} \right)^n \left(\frac{1}{1+\rho} \right)^{N+1-n}$$

dove:

$$\lambda = \text{Mean Failure Rate}, \quad \mu = \text{Mean Repair Rate}, \quad \rho = \frac{\lambda}{\mu}.$$

- stato i : numero di cammini guasti (down).
- **MFR (Mean Failure Rate)** λ : tasso medio di guasto di un singolo cammino. Se nello stato attuale ci sono 2 cammini attivi, ognuno può guastarsi indipendentemente con tasso λ .
- **MRR (Mean Repair Rate)** μ : quantifica quante volte per unità di tempo un componente viene riparato.



La **Mean Unavailability** del sistema è definita come (che almeno una tra le N connessione principale sia down):

$$U(N, \lambda, \mu) = \sum_{n=2}^{N+1} \frac{n-1}{N} p(n)$$

dove $p(n)$ è la probabilità stazionaria di trovarsi nello stato n . Per $n \geq 2$, nello stato n sono presenti $(n - 1)$ connessioni non protette sul totale di N connessioni. La probabilità che una connessione scelta a caso tra le N sia una di quelle non protette è dunque pari al rapporto:

$$\frac{n-1}{N}.$$

L'**availability** complessiva è quindi data da:

$$A = 1 - U.$$

Analysis of 1:N Protection with Service Differentiation Consideriamo N_G connessioni *Gold* e N_S connessioni *Silver*. Le *Gold* hanno priorità e possono preemptare le *Silver* nell'uso del cammino di backup. L'*unavailability* media per le *Gold* è:

$$U_G(N_G, \lambda, \mu) = \sum_{n=2}^{N_G+1} \frac{n-1}{N_G} p(n)$$


mentre per le *Silver* vale:

$$U_S(N, N_G, \lambda, \mu) = \frac{U(N, \lambda, \mu) \cdot N - U_G(N_G, \lambda, \mu) \cdot N_G}{N_S}.$$

Le connessioni *Gold* si comportano come se non vedessero le *Silver*, poiché possono preemptarle nell'utilizzo del backup. Di conseguenza, l'*unavailability* di una *Gold* equivale a quella di una connessione in un sistema con protezione 1 : N_G . L'*unavailability* totale U **si conserva**.

Analisi M:N senza differenziazione di servizio Abbiamo M cammini di protezione che proteggono N cammini primari. Il sistema è modellato con una catena di Markov a $N + M + 1$ stati. Lo stato i rappresenta i cammini (inclusi working e protection) guasti. La probabilità stazionaria si ottiene come:

$$p(n) = \binom{N+M}{n} \left(\frac{\rho}{1+\rho} \right)^n \left(\frac{1}{1+\rho} \right)^{N+M-n}$$



La **Mean Unavailability** del sistema è data da:

$$U(N, M, \lambda, \mu) = \sum_{n=M+1}^{N+M} \frac{n-M}{N} p(n)$$

dove il termine $\frac{n-M}{N}$ rappresenta la frazione di connessioni non protette nello stato n (cioè $(n - M)$ connessioni non protette su N totali). Per $n \geq M + 1$ il sistema ha esaurito la protezione, e la probabilità che una connessione scelta a caso non sia protetta è esattamente $(n - M)/N$.

Protezione M:N con differenziazione di servizio Nel caso di protezione $M:N$ con differenziazione di servizio, si considerano N_G connessioni Gold e N_S connessioni Silver, con $N = N_G + N_S$. Le connessioni Gold hanno priorità di accesso ai cammini di backup e possono *preemptare* le Silver, comportandosi come in un sistema con protezione 1: N_G . L'indisponibilità media delle connessioni Gold si calcola come:

$$U_G(N_G, M, \lambda, \mu) = \sum_{n=M+1}^{N_G+M} \frac{n-M}{N_G} p(n)$$

mentre quella delle Silver è ottenuta per conservazione dell'indisponibilità totale:

$$U_S(N, N_G, M, \lambda, \mu) = \frac{U(N, M, \lambda, \mu) \cdot N - U_G(N_G, M, \lambda, \mu) \cdot N_G}{N_S}$$

dove U rappresenta l'indisponibilità media di una connessione generica nel sistema senza differenziazione. La relazione di conservazione:

$$U \cdot N = U_S \cdot N_S + U_G \cdot N_G$$

esprime che l'indisponibilità totale sperimentata su tutti i link in un anno rimane costante, indipendentemente dall'eventuale prioritizzazione delle Gold rispetto alle Silver: la risorsa di backup viene semplicemente redistribuita, favorendo le connessioni Gold.

6 Controllo di Flusso e di Congestione

6.1 Il problema della congestione

- Una rete ideale è in grado di smaltire tutto il traffico offerto S_0 fino al raggiungimento della capacità di rete C . Se $S_0 > C$, il traffico eccedente deve essere rifiutato. Nelle reti a **commutazione di circuito**, la capacità è determinata dal numero di circuiti assegnabili e vale $S = C$. Nelle reti a **commutazione di pacchetto**, invece, si ha $S < C$, poiché in condizioni di $\rho = 1$ si verificherebbero code infinite. In generale, quindi, la congestione rappresenta il fenomeno per cui il traffico offerto eccede le risorse di capacità effettivamente disponibili nella rete.

Traffico smaltito S , traffico offerto S_0

- Il fenomeno della **congestione** si verifica quando, all'aumentare del traffico offerto S_0 , il traffico smaltito S tende a diminuire. Le cause principali possono essere:
 - cattivo utilizzo delle risorse (es. buffer dei canali di trasmissione o capacità di elaborazione);
 - variazioni nella matrice di traffico considerata nel dimensionamento;
 - variazioni nella topologia (guasti di nodi o di canali).

La saturazione di un nodo comporta sovraccarico sui nodi vicini, con ulteriore rischio di saturazione a cascata. Il fenomeno della congestione è particolarmente rilevante nelle reti a commutazione di pacchetto, dove la moltiplicazione statistica amplifica la possibilità di saturazione.



Scopo del controllo della congestione Il controllo della congestione ha come obiettivo principale quello di mantenere stabile e affidabile il funzionamento della rete. In particolare, esso deve:

- prevenire la degradazione del traffico smaltito S (**throughput o goodput**);
- evitare situazioni di **dead-lock**, tipiche di una congestione non controllata;
- garantire un utilizzo equo delle risorse disponibili tra le diverse connessioni.

Effetti della congestione: perdita di efficienza La congestione può portare a una significativa perdita di efficienza nella rete. *Quando il traffico offerto supera la capacità di gestione del nodo, alcuni flussi tendono a monopolizzare le risorse disponibili*, impedendo un'equa distribuzione del servizio. In tali condizioni, i buffer dei nodi vengono saturati da un sottoinsieme di sorgenti, riducendo drasticamente la probabilità che i pacchetti provenienti da altre sorgenti vengano serviti. Il risultato è un throughput complessivo inferiore al potenziale della rete, con spreco di risorse e degradazione della qualità di servizio. Per mitigare questo problema, i meccanismi di controllo della congestione introducono **politiche di assegnazione dei buffer eque**, mirate a garantire una migliore efficienza complessiva del sistema.


Deadlock diretto e indiretto Il **deadlock diretto** si verifica quando due nodi si bloccano reciprocamente: ognuno ha il buffer saturo di pacchetti in trasmissione verso l'altro. In questo caso la situazione di stallo coinvolge soltanto due entità, che restano bloccate in attesa di risorse che non si libereranno mai. Il **deadlock indiretto**, invece, si manifesta quando il blocco è generato da una catena di dipendenze tra più nodi. Ogni nodo ha il buffer saturo di pacchetti verso un altro nodo della catena, fino a chiudere un ciclo che impedisce a tutti i partecipanti di progredire. In questo scenario lo stallo non è più reciproco e diretto tra due soli nodi, ma si propaga attraverso un gruppo più ampio della rete.

Funzioni del Controllo di Flusso Il controllo di flusso è un insieme di procedure che hanno lo scopo di **proteggere la rete da sovraccarichi e situazioni di dead-lock**. Tali procedure agiscono su vari aspetti, come l'allocazione dei buffer nei nodi, il blocco del traffico all'interno della rete e il blocco del traffico in ingresso. Il controllo può essere realizzato a diversi livelli della rete, ma comporta sempre un **trade-off** tra le risorse utilizzate (*costo*) e il miglioramento delle prestazioni ottenuto (*benefici*).

Formulazione del Problema Per valutare le prestazioni di un sistema di rete si introduce la grandezza detta **potenza**, definita come il rapporto tra il traffico medio smaltito e il ritardo medio:

$$\text{Potenza} = \frac{(\text{Traffico smaltito})_{\text{medio}}}{(\text{Ritardo})_{\text{medio}}}.$$

Questa misura rappresenta un bilanciamento tra capacità di elaborazione del traffico e qualità del servizio percepita dagli utenti. Infatti, al crescere del traffico smaltito il ritardo tende ad aumentare, e la potenza raggiunge un massimo in corrispondenza di un punto di equilibrio. Si osserva che, per sistemi M/M/1 e più in generale M/G/1, il massimo della potenza si ottiene quando il numero medio di utenti in servizio è pari a 1.



Controllo di Flusso e della Congestione Le procedure di *controllo di flusso* hanno lo scopo di evitare che una sorgente inondi la destinazione con più traffico di quanto essa possa ricevere, garantendo così un corretto *speed matching*. Generalmente, questo meccanismo è implementato end-to-end, ma può anche essere realizzato hop-by-hop, ossia tra nodi consecutivi lungo il cammino fra sorgente e destinazione.

Le procedure di *controllo della congestione*, invece, mirano a garantire che l'intera rete non venga sovraccaricata da un traffico complessivo superiore alla propria capacità. Esse possono essere implementate all'accesso della rete, per limitare l'invio eccessivo di pacchetti da parte di un host, oppure agire sulla gestione delle risorse di memoria, assicurando fairness e prevenendo situazioni di deadlock. **In questo contesto, non viene fatta una distinzione netta tra le due terminologie.**

Livelli di Controllo della Congestione Le tecniche di controllo della congestione possono essere realizzate a diversi livelli dell'architettura di rete:

- **Internodo (Hop Level):** gestione delle congestioni locali nei buffer di linea;
- **Accesso alla rete (Network Access):** controllo della congestione nella rete di accesso;
- **End-to-End (Transport):** intervento tra sorgente e destinazione in presenza di congestione nel nodo di destinazione.

Differenza tra Buffer e Coda

- **Buffer:** rappresenta l'intera memoria disponibile nel nodo/router per contenere i pacchetti in attesa di essere trasmessi. È una risorsa globale, condivisa tra più flussi o canali. La sua dimensione totale è indicata con B .
- **Coda (Queue):** è la porzione di buffer associata ad un singolo canale di uscita. Ogni interfaccia o flusso ha la propria coda (es. una coda per i pacchetti verso l'uscita A, un'altra per l'uscita B, ecc.). L'occupazione della coda i è indicata con n_i .

In sintesi:

Buffer = memoria complessiva, Coda = suddivisione del buffer per ogni uscita o flusso.

Controllo di Flusso Hop-by-Hop e Channel Queue Limit (CQL) Il controllo di flusso *hop-by-hop* agisce localmente monitorando lo stato delle code e l'occupazione dei buffer, scartando pacchetti quando vengono superate soglie prefissate. Un meccanismo fondamentale è il **Channel Queue Limit (CQL)**, che distingue i pacchetti in base ai canali di uscita, imponendo un limite massimo alla coda e prevenendo situazioni di *deadlock* diretto, poiché garantisce la non saturazione delle memorie. Esistono due principali versioni di CQL:

- **Partizione completa:** il buffer totale B (dimensione buffer) è suddiviso in modo equo tra le N code di uscita. Se n_i rappresenta il numero di pacchetti nella coda i , vale

$$0 \leq n_i \leq \frac{B}{N}$$


- **Partizione limitata:** viene fissato un limite massimo b_M per la dimensione di ciascuna coda, con $b_M > \frac{B}{N}$. In questo caso, $0 \leq n_i \leq b_M$ e $\sum_i n_i \leq B$. Questa tecnica permette di assorbire picchi temporanei di traffico senza saturare definitivamente le risorse.
- **Partizione con buffer minimo:** ad ogni coda è garantito un buffer minimo b_m , con $b_m \leq \frac{B}{N}$, mentre lo spazio extra può essere allocato dinamicamente a chi ne ha bisogno.
- **Partizione limitata con buffer minimo:** combinazione delle due precedenti, in cui ogni coda ha un buffer minimo garantito b_m e allo stesso tempo un limite massimo b_M .

Il CQL quindi rappresenta una politica di controllo che bilancia l'uso delle risorse di memoria, garantendo equità tra flussi diversi e maggiore robustezza contro fenomeni di congestione locale.

Rate Control Il *Rate Control* è una tecnica di regolazione del traffico utilizzata prevalentemente nei punti di accesso alla rete, con lo scopo di garantire che il traffico offerto da un utente sia conforme al rate di trasmissione contrattato con il Service Provider. In tali scenari, il gestore della rete controlla che l'utente non invii più traffico di quanto la banda garantita consenta. In generale, il Rate Control assicura un ritmo medio di trasmissione stabile, consentendo tuttavia di accogliere temporanei picchi di traffico (*burst*) senza compromettere le prestazioni complessive della rete.

6.2 Token bucket


Il *Token Bucket* è una tecnica di controllo del traffico (**rate control**) ampiamente utilizzata per regolare il rate di trasmissione e permettere un uso flessibile della banda. L'idea di base consiste nell'introdurre la nozione di **token**: ogni pacchetto che deve essere trasmesso deve prima ottenere un token dalla coda dei permessi. I token vengono generati a una frequenza costante $1/r$ e accumulati in una coda di dimensione massima W ; se la coda è piena, i token in eccesso vengono scartati. Un pacchetto privo di token resta in attesa fino a quando non ne ottiene uno, garantendo così che il traffico medio non superi la capacità prevista. Questa tecnica consente però di assorbire brevi picchi di traffico (*burst*), sfruttando i token eventualmente accumulati, e al tempo stesso limita la trasmissione eccessiva, prevenendo la saturazione della rete.



Analisi del Token Bucket Il modello di analisi del *Token Bucket* si basa su alcune assunzioni fondamentali. Si considera che gli arrivi dei pacchetti seguano un processo di Poisson con parametro λ , mentre i permessi (token) vengono generati con frequenza $1/r$ secondi. Se la coda dei permessi ha già raggiunto la dimensione massima W , i nuovi token in arrivo vengono scartati. Il comportamento del sistema può essere descritto tramite una **catena di Markov a tempo discreto**, dove gli stati rappresentano il numero di permessi disponibili e il numero di pacchetti in attesa di trasmissione. In particolare:

- se ci sono $W - i$ permessi disponibili, non vi sono pacchetti in attesa;
- se ci sono $i - W$ pacchetti in attesa di permesso, significa che i token sono stati consumati e la coda è in attesa di rigenerazione.

Questo modello consente di studiare le probabilità di attesa, perdita dei pacchetti e il comportamento del sistema al variare dei parametri (λ, r, W) . In tal modo è possibile ottimizzare le prestazioni e ridurre i rischi di congestione.



Transizioni nel modello di Token Bucket Nel modello markoviano del *Token Bucket*, le transizioni tra stati avvengono agli istanti di arrivo dei permessi, ovvero ogni $1/r$ secondi. In questo intervallo, il numero di pacchetti che arrivano segue una distribuzione di Poisson con parametro λ/r . La probabilità che arrivino k pacchetti è quindi:

$$a_k = P\{k \text{ arrivi in } 1/r\} = \frac{\left(\frac{\lambda}{r}\right)^k}{k!} e^{-\lambda/r}.$$


Le probabilità di transizione si definiscono come:

$$P_{0i} = \begin{cases} a_{i+1}, & i \geq 1 \\ a_0 + a_1, & i = 0 \end{cases} \quad P_{ji} = \begin{cases} a_{i-j+1}, & j \leq i+1 \\ 0, & \text{altrimenti} \end{cases} \quad \text{per } j \geq 1$$

Il diagramma a stati rappresenta le dinamiche del sistema:

- ogni $1/r$ secondi viene generato un token;
- se non arrivano pacchetti ($k = 0$), il token rimane inutilizzato o va perso se la coda dei permessi è piena (W);
- se arrivano pacchetti, essi consumano immediatamente i token disponibili, con la possibilità di restare in attesa in coda;
- quando arrivano più pacchetti dei permessi disponibili, si formano code di attesa o si verificano perdite se la capacità è superata.

Questo meccanismo consente di modellare con precisione il comportamento del *Token Bucket* al variare degli arrivi, bilanciando la generazione regolare dei token con la natura stocastica del traffico.



Analizziamo le transizioni prendendo come riferimento lo stato ①:

- a_0 (0 arrivi in $\frac{1}{r}$): viene generato un token poiché è trascorso l'intervallo $1/r$. Questo token riempie la coda dei permessi, che passa da $W - 1$ a W .

- a_1 (1 arrivo in $\frac{1}{r}$): arriva un pacchetto che consuma immediatamente il token generato, per cui il sistema rimane nello stato 1.
- a_2 (2 arrivi in $\frac{1}{r}$): arrivano due pacchetti; uno consuma il token generato e l'altro si mette in coda, determinando il passaggio allo stato 2.

Analisi del Token Bucket: calcolo di p_0 Il calcolo della probabilità p_0 (ovvero la probabilità di trovarsi nello stato 0) può essere ottenuto imponendo la condizione di normalizzazione:

$$\sum_i p_i = 1.$$

In alternativa, si può ragionare in termini di frequenze medie:

- La frequenza media con cui i permessi entrano nel sistema è

$$(1 - p_0 a_0)r,$$

dove r rappresenta il traffico offerto, a_0 la probabilità che non arrivi alcun pacchetto nell'intervallo $1/r$, e $(1 - p_0 a_0)$ tiene conto del traffico effettivamente accettato (al netto delle perdite).

- La frequenza media dei pacchetti in arrivo è λ .

In condizioni stazionarie deve valere l'uguaglianza:

$$\lambda = (1 - p_0 a_0)r.$$

Da questa relazione si ricava la probabilità p_0 come:

$$p_0 = \frac{r - \lambda}{r a_0}.$$

Infine, per la stabilità del sistema deve valere la condizione:

$$\lambda < r.$$

Nota: si assume che la coda dei pacchetti abbia capacità infinita.

Analisi del Token Bucket: tempo medio di attesa Il tempo medio di attesa T per ottenere un permesso può essere espresso come:

$$T = \sum_{j=W+1}^{\infty} \frac{1}{r} (j - W) p_j,$$

dove W rappresenta la dimensione massima della coda dei permessi, r il rate di arrivo dei token e p_j la probabilità di trovarsi nello stato j .

Questo ritardo è attribuibile alla *coda dei pacchetti in attesa di permessi*: i pacchetti, infatti, non possono essere inoltrati finché non recuperano un token valido.

Nel caso reale, gli arrivi non sono sempre di tipo *Poissoniano*, ma possono avvenire anche in **burst**, rendendo quindi la gestione del ritardo e della congestione più complessa.

7 Domande teoria

- Si enunci e si dimostri con chiarezza e precisione il Teorema di Little (Little's Result), riportando la dimostrazione di Stidham.



Il **Risultato di Little** mette in relazione tre quantità fondamentali di un sistema in **condizioni stazionarie** (il traffico accettato è uguale al traffico smaltito):

- λ : frequenza **media** ingressi, [utenti/secondo] (traffico accettato),
- N : il numero **medio** di utenti presenti nel sistema (coda + servizio),
- T : tempo di permanenza **medio** di un utente nel sistema (coda + servizio).

La relazione è la seguente:

$$N = \lambda \cdot T$$

Questo risultato è molto potente perché vale in generale, indipendentemente da :


- distribuzione delle lunghezze dei pacchetti
- distribuzione degli interarrivi
- metodi di instradamento

NB: posso applicare tale teorema sia sul sistema sia sulla coda.

Dimostrazione di Stidham:

- Supponiamo che ogni utente paghi 1 Euro per ogni unità di tempo trascorsa nel sistema.
- L'incasso totale atteso per unità di tempo sarà pari a N Euro, dove N è il numero medio di utenti presenti nel sistema.
- Il costo medio pagato da ciascun utente è T Euro, dove T è il tempo medio trascorso nel sistema.
- Se facciamo pagare all'ingresso (o all'uscita), nell'unità di tempo si raccoglieranno in media λT Euro, dove λ è il tasso medio di arrivo.
- Quindi l'incasso per unità di tempo può essere espresso sia come N che come λT .

- Si calcoli, illustrando i passaggi matematici, la densità di probabilità della variabile “intervallo fra due uscite” di un sistema MM1 di parametri λ (frequenza media arrivi) e $1/\mu$ (durata media tempo di servizio)



la densità di probabilità dell'intervallo tra due uscite, $f_t(t)$ è data dalla somma pesata dei contributi dei due casi:

$$f_t(t) = \rho \mu e^{-\mu t} + (1 - \rho) \mu e^{-\mu t} * \lambda e^{-\lambda t}$$

Nel **dominio delle frequenze (Laplace)**: la trasformata di Laplace di una convoluzione è il prodotto delle singole trasformate di Laplace

$$\textcircled{1} \mathcal{L} [\rho \mu e^{-\mu t}] = \rho \cdot \mathcal{L} [\mu e^{-\mu t}] = \rho \frac{\mu}{\mu + s}$$

$$\textcircled{2} \mathcal{L} [(1 - \rho)(\mu e^{-\mu t} * \lambda e^{-\lambda t})] = (1 - \rho) \cdot \mathcal{L} [\mu e^{-\mu t}] \cdot \mathcal{L} [\lambda e^{-\lambda t}] = (1 - \rho) \cdot \frac{\mu}{\mu + s} \cdot \frac{\lambda}{\lambda + s}$$

$$F_t(s) = \rho \frac{\mu}{\mu + s} + (1 - \rho) \frac{\mu}{\mu + s} \cdot \frac{\lambda}{\lambda + s} = \frac{\lambda}{\lambda + s}$$

da cui - **Poisson con valore medio λ** : $f_t(t) = \lambda \cdot e^{-\lambda t}$

Osservazioni:

- $\textcircled{1}$ il servente sta lavorando continuamente. Ogni volta che un cliente finisce il servizio, ce n'è subito un altro pronto in coda. Il tempo tra due uscite consecutive sarà quindi determinato solo dal tempo di servizio, che è distribuito esponenzialmente con parametro μ . La probabilità che il servente stia lavorando (cioè che il sistema non sia vuoto) è data da $\rho = \lambda/\mu$ (l'intensità di traffico).
- $\textcircled{2}$ il servente si è svuotato. Deve prima attendere che arrivi un nuovo utente e poi servirlo. Una volta che il nuovo cliente arriva, il servente inizia a servirlo. Quindi, l'intervallo tra le uscite comprende due parti: il tempo di attesa per un nuovo arrivo, che, dato che gli arrivi sono Poisson, è distribuito esponenzialmente con parametro λ e il tempo di servizio di quel cliente, che è distribuito esponenzialmente con parametro μ . La probabilità che il servente si sia svuotato (cioè che il sistema sia vuoto) è $(1 - \rho)$. Dato che stiamo sommando due variabili esponenziali indipendenti (tempo di inter-arrivo e tempo di servizio), la distribuzione risultante è una convoluzione delle due distribuzioni esponenziali (la convoluzione si indica con l'asterisco).

NB: ρ indica la frazione di tempo in cui il servente è effettivamente occupato (cioè sta lavorando). Definito come: λ (tasso di arrivo) / μ (tasso di servizio). Dunque se ρ rappresenta la probabilità che il servente sia occupato, allora $1 - \rho$ rappresenta la probabilità che il sistema sia vuoto (o che il servente sia inattivo).

Conclusione: dunque l'intervallo tra due uscite da un sistema $M|M|1$ (e più in generale da un sistema $M|M|m$) è esso stesso un processo di Poisson, con lo stesso tasso di arrivo λ . Questo è un risultato fondamentale noto come **Teorema di Burke**.

In parole povere, significa che in un sistema $M|M|1$ (o $M|M|m$), anche se il sistema può essere occupato o vuoto in momenti diversi, se si guardano solo le uscite, esse si verificano come se fossero generate da un nuovo processo di Poisson indipendente, con lo stesso tasso del processo di arrivo.

- Si enunci e si dimostri, illustrandone i passaggi, la cosiddetta Pollaczek-Khinchin (P-K) Formula.

Distribuzione generica

Enunciato: nel modello $M|G|1$, il tempo medio di attesa in coda W è dato da:

$$W = \frac{\lambda \bar{x}^2}{2(1-\rho)} \quad \text{da cui: } T = \bar{x} + W$$

dove:

- λ è il tasso medio di arrivo;
- X è la variabile aleatoria che rappresenta il tempo di servizio;
- $\bar{x} = 1/\mu$ è il tempo medio di servizio;
- $\bar{x}^2$ è il momento secondo del tempo di servizio;
- $\rho = \lambda \bar{x}$ è il carico del sistema ($\rho < 1$ per stabilità).

Ipotesi: supponiamo o inoltre che gli utenti siano serviti nello stesso ordine con cui arrivano al sistema $\Rightarrow$ **FCFS**.

Dimostrazione (schema): sia W_i il tempo di attesa in coda del cliente i :

$$W_i = R_i + \sum_{j=i-N_i}^{i-1} x_j$$

dove:

- R_i tempo di servizio residuo visto dall'utente i (se il sistema è vuoto quando arriva i , allora $R_i = 0$). **Ovvero:** quanto deve attendere l' i -esimo utente perché chi è nel servizio al momento del suo arrivo finisca.
- N_i utenti in coda all'arrivo dell'utente i ;
- x_j i tempi di servizio degli utenti in coda.
- **iid** supponendo ci sia indipendenza fra N_i e X_i
- N_q numero medio di utenti in coda

$$W_i = R_i + \sum_{j=i-N_i}^{i-1} x_j$$

$$\mathbb{E}[W_i] = \mathbb{E}[R_i] + \mathbb{E}\left[\sum_j \mathbb{E}[X_j | N_i]\right] \stackrel{iid}{=} \mathbb{E}[R_i] + \bar{x} \cdot \mathbb{E}[N_i]$$


$$W = R + \bar{x} \cdot N_q$$

Little applicato al sotto-sistema coda: $N_q = \lambda \cdot W$

Sapendo inoltre che: $\rho = \lambda \cdot \bar{x}$

$$\begin{aligned} W &= R + \bar{x} \cdot N_q \\ &= R + \bar{x} \cdot \lambda W \\ &= \frac{R}{1-\rho} \end{aligned}$$

Resta ora da determinare R :



$$\begin{aligned} \mathbb{E}[r(\tau)] &= \frac{1}{t} \int_0^t r(\tau) d\tau = \frac{1}{t} \sum_{i=1}^{M(t)} \frac{1}{2} x_i^2 \\ &= \frac{1}{2} \cdot \frac{M(t)}{t} \cdot \frac{\sum_{i=1}^{M(t)} x_i^2}{M(t)} \end{aligned}$$

Assumendo che: $\exists \lim_{t \rightarrow \infty}$ **avremo che:**

$$\begin{aligned} \lim_{t \rightarrow \infty} \frac{1}{t} \int_0^t r(\tau) d\tau &= \frac{1}{2} \lim_{t \rightarrow \infty} \frac{M(t)}{t} \cdot \lim_{t \rightarrow \infty} \frac{\sum_{i=1}^{M(t)} x_i^2}{M(t)} \\ R &= \frac{1}{2} \cdot \lambda \cdot \bar{x}^2 \end{aligned}$$

Note:

- Per calcolare R scelgo un intervallo $(0, t)$ tale che $r(t) = 0$ in $(0, t)$, ovvero un intervallo in cui si trovano solo triangoli interi (non tagliati). Questo è sempre possibile perché $\lambda < \mu$ implica che il sistema si svuota in infiniti istanti (**periodi di inattività** o *idle periods*).
- $M(t)$ è il numero di servizi completati nell'intervallo $(0, t)$, ovvero il numero di triangoli considerati.

Sostituendo otteniamo:

$$W = \frac{\lambda \bar{x}^2}{2(1-\rho)}$$

Osservazioni:

- W dipende solo dai primi due momenti della distribuzione dei tempi di servizio.

- **Ipotesi:** esistenza della media a regime di W, R, N_q , ergodicità (media temporale = medie di insieme).
- Cresce all'aumentare della varianza $(\bar{x}^2 - \bar{x}^2)$.
- Diverge per $\rho \rightarrow 1$.
- Valida anche se l'ordine di servizio degli utenti non è FCFS purché la scelta dell'utente non dipenda dal tempo di servizio richiesto.
- **Si enunci con chiarezza e precisione il teorema di Burke, indicando inoltre quale è la sua utilità nello studio delle reti di code.**

- In un sistema $M|M|1$, $M|M|m$ o $M|M|\infty$, con qualunque disciplina di coda e in regime stazionario, se il tasso medio degli arrivi è λ , allora:

Il processo in uscita è ancora di Poisson con tasso medio λ .

- **Esempio – Cascata di code:** l'ingresso di ogni coda coincide con l'uscita della precedente, quindi se la prima ha un'uscita di Poisson a tasso λ , anche le successive la riceveranno come processo di Poisson con lo stesso tasso.
- **Osservazione:** i tempi di attraversamento di nodi diversi **non sono, in generale, indipendenti** (ad esempio un messaggio lungo richiede tempi lunghi in tutte le code che attraversa), ma il teorema garantisce comunque la natura Poissoniana del flusso medio.

anche se i flussi sono correlati

- **Osservazione importante:** si assume che i tempi di servizio siano indipendenti da nodo a nodo. In realtà, un pacchetto “lungo” in uscita da una coda tenderà ad avere un tempo di servizio “lungo” anche nella coda successiva. Tuttavia, se molti flussi indipendenti si mescolano all'ingresso di una coda, la somma dei traffici diventa sufficientemente casuale da soddisfare l'ipotesi di indipendenza. Questa approssimazione è nota come **Kleinrock independence approximation**.
- **Si illustri con chiarezza e precisione in cosa consiste la tecnica di routing cosiddetta flooding (o inondazione), indicandone vantaggi e svantaggi e possibili ambiti di applicazione.**
 - **Definizione e funzionamento.** nella tecnica di *flooding* o di diffusione (instradamento deterministico) ogni nodo, quando riceve un pacchetto, ne inoltra una copia su *tutte* le interfacce in uscita *eccetto* quella da cui l'ha ricevuto; così il messaggio si propaga a tutti i nodi raggiungibili della rete. Per evitare ricicli infiniti si usa un identificativo univoco (ID) del pacchetto o un contatore di hop/TTL, memorizzando localmente gli ID già visti.
 - **Vantaggi.** (i) *Affidabilità elevata:* se esiste almeno un cammino, il pacchetto raggiunge la destinazione; (ii) semplicità concettuale; (iii) utile per scoprire topologia/percorsi o diffondere rapidamente informazione di stato di collegamento.

- **Svantaggi.** (i) elevato traffico - molti duplicati; (ii) ritardo medio maggiore T^* ; (iii) necessità di memoria per la tabella degli ID (maggiore complessità implementativa).
- **Varianti e ambiti d'uso.**
 - * *Diffusione selettiva:* si inoltra solo su un sottoinsieme di uscite (es. in base alla direzione).
 - * *Broadcast su spanning tree:* si pre-calcola uno spanning tree e si inoltra solo sugli archi dello ST, eliminando i duplicati.
 - * *Applicazioni tipiche:* reti con basso utilizzo ma requisiti stringenti di affidabilità (es. contesti militari) o come meccanismo ausiliario nei protocolli di routing per distribuire informazioni di stato.

- **Si illustri con chiarezza e precisione la differenza tra albero dei cammini minimi e albero di costo minimo, in una rete di telecomunicazione.**

Definizioni formali. Sia N l'insieme dei nodi e $A = \{(i, j) : i, j \in N\}$ l'insieme di archi (coppia ordinata di nodi). Definiamo $G = (N, A)$ un grafo pesato con costi c_{ij} su ogni arco $(i, j) \in A$.

- **Albero dei cammini minimi (SPT) radicato in $s \in N$:** è l'insieme dei cammini da s a ciascun nodo $d \in N$ tali da minimizzare la somma dei costi sugli archi del cammino:

$$\min_{\text{cammini } s \rightarrow d} \sum_{(i,j) \text{ nel cammino}} c_{ij}.$$

Dipende dalla scelta della radice s e garantisce la minima distanza da s a ogni altro nodo. Si calcola tipicamente con Dijkstra (costi non negativi) o Bellman–Ford (ammette costi negativi senza cicli negativi).

- **Albero di copertura di costo minimo (MST):** è un sottoinsieme di archi che collega tutti i nodi di N con il minimo costo totale:

$$\min_{\text{alberi di copertura}} \sum_{(i,j) \text{ nell'albero}} c_{ij}.$$

È indipendente dalla scelta di una sorgente ed è usato per problemi di copertura (broadcast/multicast) o di progettazione fisica della rete. Si calcola con Kruskal o Prim.

SPT (Shortest-Path Tree)

Minimizza distanze da una sorgente s
 Dipende dalla sorgente s
 Cammini $s \rightarrow d$ sono minimi
 Usi: instradamento unicast
 Alg.: Dijkstra, Bellman–Ford

MST (Minimum Spanning Tree)

Minimizza costo totale degli archi
 Non dipende da alcuna sorgente
 Cammini $u \rightarrow v$ non necessariamente min
 Usi: broadcast/multicast
 Alg.: Kruskal, Prim

- **Si illustri con chiarezza e precisione in che cosa consiste e a cosa serve il metodo cosiddetto della deviazione di flusso (flow deviation).**

Definizione formale. Il *metodo della deviazione di flusso* è un algoritmo iterativo per l'*instradamento ottimo* (assegnamento dei flussi) che consiste nello spostare piccole quantità (infinitesime) di traffico f_{ab} da un cammino Π_2 sub-ottimo (a ritardo elevato) a un cammino Π_1 con ritardo minore. Se λ_k è il flusso sul lato $k \in \Pi_1$ e λ_h è il flusso sul lato $h \in \Pi_2$, dopo la deviazione si ha:

$$\lambda'_k = \lambda_k + f_{ab}, \quad k \in \Pi_1$$

$$\lambda'_h = \lambda_h - f_{ab}, \quad h \in \Pi_2$$

Il processo continua finché la pendenza (derivata del ritardo) dei due cammini diventa uguale; a quel punto non conviene più spostare traffico.

Algoritmo.

1. Impostare la lunghezza del lato: misura quanto aumenta il ritardo se il traffico cresce di una piccola quantità

$$\ell_i = \frac{\partial T_i}{\partial \lambda_i}$$

2. Calcolare i cammini più corti fra ogni coppia (i, j) utilizzando Dijkstra.
3. Instradare f_{ij} lungo il cammino più corto (costo minimo).

Note.

- Per T_i si può usare l'approssimazione in cui ogni lato è modellato come una coda $M|M|1$:

$$T_i = \frac{1}{\mu_i - \lambda_i} \Rightarrow \ell_i = \frac{\partial}{\partial \lambda_i} \left(\frac{1}{\mu_i - \lambda_i} \right) = \frac{1}{(\mu_i - \lambda_i)^2}$$

- È necessario utilizzare deviazioni piccole di traffico per evitare instabilità.

Obiettivo. Ridurre il grado di servizio dalla rete T^* (ritardo medio) ottimizzando l'allocazione dei flussi e rispettando i vincoli di capacità.

• Si indichino con chiarezza e precisione le caratteristiche e differenze di:

- **simulazioni deterministiche e casuali;**
- **simulazioni Monte-Carlo e temporali;**
- **simulazioni a eventi discreti.**

- **Simulazioni deterministiche:** tutti i parametri e le condizioni iniziali sono fissati; l'evoluzione del sistema è completamente prevedibile e, a parità di input, produce sempre lo stesso output.

- **Simulazioni casuali (o stocastiche):** sono basati su modelli che includono variabili o processi casuali e necessitano della generazione di variabili casuali; ripetizioni con gli stessi parametri possono produrre risultati diversi, richiedendo analisi statistica degli output.

Tra le simulazioni casuali possiamo distinguere quelle **statiche** (dette anche simulazioni Monte-Carlo) e quelle **dinamiche** (dette anche temporali).

- **Simulazioni Monte-Carlo (o simulazioni statiche):** simulazioni casuali in cui la variabile tempo non ha alcun ruolo. Lo scopo principale è determinare caratteristiche statistiche (media, varianza, ect) di una o più variabili casuali attraverso l'escuzione di numerosi esperimenti ripetuti in modo indipendente.
- **Simulazioni temporali (o simulazioni dinamiche):** simulazioni casuali in cui il tempo è la variabile principale che governa l'evoluzione del modello. L'obiettivo è raccogliere dati statistici su processi casuali osservati al variare del tempo. Le osservazioni sono critiche poiché:

- * a differenza delle prove indipendenti tipiche delle simulazioni statiche, le osservazioni risultano correlate e occorre tenere conto della **correlazione statistica** dovuta dal fattore temporale+;
- * non è possibile sapere a priori se il processo osservato sia **ergodico**, cioè se il sistema sia stabile o se lo si stia osservando in regime transitorio.

- **Simulazioni a eventi discreti:** sono un approccio di simulazione in cui l'evoluzione di un sistema è guidata da *eventi* che avvengono in istanti ben definiti, piuttosto che da un aggiornamento continuo nel tempo. In questo contesto:

- * In una simulazione a eventi discreti lo stato del sistema rimane invariato tra due eventi consecutivi e viene aggiornato solo nel momento in cui si verifica un evento.
- * Un *evento* è un'azione istantanea che provoca un cambiamento nello stato (istante preciso, non ha durata).
- * Un'*attività* rappresenta invece una condizione che dura per un intervallo di tempo (es. trasmissione di un pacchetto) ed è delimitata da due eventi: inizio e fine.
- * La gestione della simulazione richiede un *calendario degli eventi*, una struttura dati che memorizza tutti gli eventi futuri ordinati per tempo di occorrenza.
- * L'algoritmo principale della simulazione scorre il calendario:
 1. estrae l'evento più vicino nel tempo,
 2. aggiorna lo stato del sistema in base a quell'evento,
 3. programma eventuali nuovi eventi conseguenti.
- * Se il modello è stocastico, i tempi e le caratteristiche degli eventi vengono generati tramite numeri pseudo-casuali con distribuzioni coerenti al fenomeno reale.

- **Si illustri con chiarezza e precisione in cosa consiste il metodo di Von Neumann (o metodo di reiezione), illustrato a lezione, per la generazione di sequenze pseudo-casuali.**

Definizione. Il *metodo di Von Neumann*, noto anche come metodo del *centro del quadrato*, è stato uno dei primi algoritmi proposti per la generazione di sequenze pseudo-casuali. È un metodo deterministico che, a partire da un numero iniziale (seme), produce nuovi numeri applicando una trasformazione matematica semplice ma ricorsiva.

Procedura. Dato un numero intero x_0 con d cifre:

1. Elevare x_0 al quadrato: $y_0 = x_0^2$.
2. Se y_0 ha meno di $2d$ cifre, aggiungere zeri iniziali fino ad avere $2d$ cifre.
3. Estrarre le d cifre centrali di y_0 per ottenere il nuovo numero x_1 .
4. Ripetere il processo con x_1 per ottenere x_2 , e così via.

Le cifre centrali estratte possono essere normalizzate in $[0, 1]$ per ottenere un numero pseudo-casuale:

$$u_n = \frac{x_n}{10^d}.$$

Esempio. Sia $x_0 = 5735$ ($d = 4$):

$$x_0^2 = 32890225 \Rightarrow x_1 = 8902$$

$$x_1^2 = 79245604 \Rightarrow x_2 = 2456$$

e così via.

Caratteristiche e limiti.

- Metodo semplice da implementare.
- Può generare sequenze di lunghezza limitata: tende a produrre cicli corti o a convergere a 0.
- Sensibile alla scelta del seme iniziale: semi “deboli” portano rapidamente a degenerazione della sequenza.

Stato attuale. Il metodo è stato abbandonato nella pratica per le sue scarse proprietà statistiche e la bassa qualità della casualità prodotta. I metodi moderni usano varianti della **congruenza lineare**, che offrono periodi più lunghi e una distribuzione più uniforme.

- **Si illustri con chiarezza e precisione in che cosa consiste e come funziona il metodo del percentile per la generazione di numeri pseudocasuali dimostrando, con il semplice passaggio matematico illustrato a lezione, perché funziona. Si indichino inoltre quali sono i limiti di questo metodo.**


Idea generale del metodo del percentile (o dell'inversa). L'obiettivo è quello di generare variabili casuali con una distribuzione arbitraria a partire da numeri pseudocasuali che un calcolatore è in grado di produrre facilmente, cioè numeri uniformi nell'intervallo $[0, 1]$. Il metodo del *percentile*, detto anche metodo dell'inversa della funzione di ripartizione, sfrutta proprio questa possibilità: trasformare una variabile uniforme in una variabile con la distribuzione desiderata tramite la funzione di ripartizione cumulativa (CDF) $F_X(x)$ della variabile.

I passi sono i seguenti:

1. Si genera un numero pseudocasuale uniforme $U \sim \mathcal{U}(0, 1)$.
2. Si considera la CDF $F_X(x)$ della variabile X che vogliamo sintetizzare.
3. Si calcola l'inversa della funzione di ripartizione, $F_X^{-1}(u)$.
4. Si definisce quindi:

$$X = F_X^{-1}(U).$$

In questo modo si ottiene una nuova variabile casuale X distribuita secondo la distribuzione originale $F_X(x)$.



Teorema fondamentale delle funzioni di variabili aleatorie. Il metodo si fonda direttamente su questo teorema, che afferma: se $U \sim \mathcal{U}(0, 1)$ e poniamo $X = F_X^{-1}(U)$, allora la variabile X ha distribuzione di ripartizione proprio $F_X(x)$. In altre parole, il teorema garantisce che sia possibile *sintetizzare* una variabile con qualsiasi distribuzione nota a partire da una distribuzione uniforme.

Dimostrazione sintetizzata. Sia $U \sim \mathcal{U}(0, 1)$. Definiamo $X = F_X^{-1}(U)$. Allora:

$$\mathbb{P}[X \leq x] = \mathbb{P}[F_X^{-1}(U) \leq x] = \mathbb{P}[U \leq F_X(x)].$$

Poiché U è uniforme su $[0, 1]$, risulta:

$$\mathbb{P}[U \leq F_X(x)] = F_X(x).$$

Quindi X ha distribuzione di ripartizione $F_X(x)$, come volevasi dimostrare.

Limiti del metodo.

- **Invertibilità:** il metodo richiede che $F_X(x)$ sia invertibile in forma chiusa. Per distribuzioni semplici (esponenziale, uniforme) funziona bene, mentre per altre (es. normale) non esiste un'inversa esplicita.
- **Efficienza:** quando l'inversa deve essere calcolata numericamente, il metodo può essere poco efficiente.
- **Precisione:** errori numerici nelle approssimazioni dell'inversa peggiorano la qualità della simulazione, specialmente per distribuzioni con code pesanti.

Sintetizzare Per sintesi di una variabile aleatoria si intende la costruzione (o simulazione) di realizzazioni di una variabile casuale X con una certa distribuzione assegnata, a partire da numeri pseudo-casuali uniformi in $(0, 1)$.

- **Si illustri con precisione che cosa si intende per protezione dedicata e protezione condivisa (shared) nelle reti di telecomunicazione. (facoltativo)** Con riferimento alle reti ottiche, si illustri qual è la differenza fra protezione dedicata 1:1 e 1+1.

Protezione dedicata. Nella protezione dedicata ogni cammino primario è associato uno o più cammini di backup esclusivi, le cui risorse vengono prenotate in anticipo e non sono utilizzabili da altre connessioni. Questo schema, tipicamente implementato nelle forme 1:1, 1+1, N:1, garantisce un livello molto elevato di disponibilità: in assenza di guasti multipli concorrenti, la connessione risulta praticamente sempre protetta e il ripristino avviene in tempi estremamente rapidi. Il vantaggio principale è quindi l'aumento significativo della disponibilità end-to-end, mentre il principale svantaggio è il costo in termini di risorse: la ridondanza è pari al 100%, poiché ogni connessione richiede un percorso alternativo dedicato.

Protezione condivisa (Shared Protection). La protezione condivisa adotta un approccio differente: più cammini primari fanno affidamento sullo stesso insieme di risorse di backup. Questo modello parte dall'osservazione che i guasti multipli simultanei sono eventi poco probabili, e quindi non è necessario predisporre un backup dedicato per ogni singola connessione. Il principale vantaggio di questa tecnica è l'efficienza nell'uso delle risorse: la capacità di protezione richiesta è minore e la rete può garantire elevati livelli di disponibilità senza la necessità di duplicare completamente le risorse. Tuttavia, in caso di guasti multipli o concorrenti, le connessioni coinvolte devono contendersi lo stesso canale di backup, con una conseguente riduzione della disponibilità e tempi di ripristino generalmente più lunghi rispetto allo schema dedicato.

(Facoltativo) Differenza fra 1:1 e 1+1 nelle reti ottiche.

– **Protezione 1:1:**

- * Il traffico passa solo sul cammino primario.
- * Il cammino di backup resta inattivo fino al guasto.
- * In caso di guasto il traffico viene commutato sul backup.
- * Più efficiente in termini di banda, poiché il backup può trasportare traffico a bassa priorità finché non serve per la protezione.

– **Protezione 1+1:**

- * Il traffico è trasmesso in parallelo sia sul primario che sul backup.
- * Il ricevente seleziona in tempo reale il flusso migliore.
- * Massima disponibilità, con ripristino immediato.
- * Maggior spreco di risorse, poiché la banda del backup è sempre occupata.

- **Si illustri con chiarezza e precisione a che cosa serve ed in cosa consiste la tecnica di controllo cosiddetta Channel Queue Limit (CQL)**

La tecnica di controllo **Channel Queue Limit (CQL)** ha l'obiettivo di prevenire la congestione e i fenomeni di *deadlock* nei nodi di rete, garantendo al tempo stesso un uso equo delle risorse di memoria. In particolare, il CQL opera in modalità **hop-by-hop**, cioè localmente su ciascun nodo o router, monitorando le **code di uscita** e l'occupazione del **buffer**. Per ciascuna coda viene fissato un limite massimo, in modo da evitare che un singolo flusso possa monopolizzare tutta la memoria disponibile. Se la soglia prefissata viene superata, i pacchetti eccedenti vengono scartati.

La tecnica può essere implementata secondo diverse modalità:

- **Partizione completa:** il buffer totale B (dimensione buffer) è suddiviso in modo equo tra le N code di uscita. Se n_i rappresenta il numero di pacchetti nella coda i , vale

$$0 \leq n_i \leq \frac{B}{N}$$

- **Partizione limitata:** viene fissato un limite massimo b_M per la dimensione di ciascuna coda, con $b_M > \frac{B}{N}$. In questo caso, $0 \leq n_i \leq b_M$ e $\sum_i n_i \leq B$. Questa tecnica permette di assorbire picchi temporanei di traffico senza saturare definitivamente le risorse.
- **Partizione con buffer minimo:** ad ogni coda è garantito un buffer minimo b_m , con $b_m \leq \frac{B}{N}$, mentre lo spazio extra può essere allocato dinamicamente a chi ne ha bisogno.
- **Partizione limitata con buffer minimo:** combinazione delle due precedenti, in cui ogni coda ha un buffer minimo garantito b_m e allo stesso tempo un limite massimo b_M .

In sintesi, il CQL è un meccanismo di **allocazione e protezione delle risorse di memoria nei router**, fondamentale per mantenere prestazioni stabili della rete, ridurre le perdite dovute a congestione e garantire equità tra flussi.

- **Si indichino con chiarezza e precisione quali sono i principali problemi che presenta l'utilizzo del protocollo TCP su reti wireless. Si indichino inoltre le principali tipologie di soluzione a tale problema illustrate a lezione, illustrandone brevemente le caratteristiche.**

Problemi principali di TCP su reti wireless TCP è stato progettato per reti cablate, dove le perdite di pacchetto sono dovute quasi sempre a *congestione*. Nelle reti wireless emergono invece ulteriori criticità:

variazione della potenza del segnale ricevuto a causa di riflessioni

- **Perdite casuali di segmenti:** dovute a interferenze, fading, mobilità o disconnessioni. TCP le interpreta come congestione e riduce inutilmente il ritmo di trasmissione dimezzando il valore della finestra di trasmissione, peggiorando le prestazioni.
- **Ritardi elevati e variabili:** dovuti alla variabilità dei canali radio e alla bassa capacità (20 kbit/s). Ciò porta e ad avere elevati ritardi, ovvero un Round Trip Time (RTT) medio molto elevato che si traduce in Retransmission Time-Out (RTO) cospicui e riduzione del throughput.

- **Canali asimmetrici:** gli ACK possono arrivare irregolarmente o non arrivare, bloccando l'avanzamento della finestra TCP e causando trasmissioni a burst.
- **Disconnessioni frequenti:** È il processo con cui una connessione mobile cambia cella (cioè cambia stazione base di riferimento) durante il movimento dell'utente. per handoff, fading o mancanza di copertura. Alla riconnessione, TCP riparte da slow-start, con drastico calo di throughput.

Principali tipologie di soluzioni Le soluzioni individuate si dividono in tre categorie:

- **Soluzioni Link Layer:** queste soluzioni operano a livello *MAC* o a livello di *base station* (es. protocollo *Snoop*) e mirano a mascherare le caratteristiche dei canali wireless mediante meccanismi locali di controllo degli errori. In particolare, i pacchetti vengono bufferizzati presso i nodi di accesso (ad es. access points) e ritrasmessi localmente in caso di perdita sul link radio.

Caratteristiche principali:

- * mascherano gli errori del link wireless ai protocolli di trasporto soprastanti (TCP);
- * sono *trasparenti* rispetto a TCP, cioè non richiedono modifiche allo stack protocollare negli host;
- * possono essere più o meno *TCP-aware*, ossia tenere conto del comportamento del protocollo di trasporto per ottimizzare le prestazioni;
- * mantengono la semantica end-to-end di TCP.

Vantaggi: migliorano le prestazioni di TCP nascondendo le perdite dovute agli errori del canale wireless, senza necessità di modifiche negli host.

Svantaggi: richiedono buffer e logica di ritrasmissione aggiuntiva nei nodi della rete di accesso (es. access point, base station). Inoltre, l'host rimane esposto solo a perdite dovute a congestione, ma non a quelle dovute al mezzo radio.

- **Soluzioni Indirect:** consistono nello spezzare la connessione TCP a livello della *base station*, creando due sotto-connessioni: una tra il mobile host e la base station e una tra la base station e l'host fisso (es. server). Sulla prima connessione, più critica, si può usare un protocollo di trasporto “ad hoc” adattato alle caratteristiche del link wireless.

Vantaggi: permettono di ottimizzare le prestazioni sul tratto wireless e richiedono poche modifiche al mobile host.

Svantaggi: la semantica end-to-end di TCP non viene mantenuta e si introduce maggiore complessità nella base station.

- **Soluzioni End-to-End:** queste soluzioni mantengono la semantica end-to-end tipica del TCP, senza spezzare la connessione alla base station. Richiedono però modifiche che possono essere localizzate:
 - * al lato trasmettitore (server),
 - * al lato ricevitore (host),
 - * oppure ad entrambi i lati.

Le principali caratteristiche sono:

1. Mantenimento della semantica end-to-end del TCP.
2. Possibilità di realizzare algoritmi avanzati di controllo della congestione e di recupero dagli errori.
3. Facilità di diffusione nella rete Internet se le modifiche sono lato server, mentre l'aggiornamento degli host richiede tempi più lunghi.

In letteratura esistono diversi approcci end-to-end:

- * **Algoritmi impliciti** (es. *TIBET*, *TCP Westwood*): stimano la causa delle perdite a partire dalla misura del throughput e dalla stima della banda disponibile.
- * **Algoritmi espliciti** (es. *TCP NewReno-LDA*): utilizzano algoritmi di Loss Differentiation (LDA) per distinguere tra perdite da congestione e perdite dovute al canale wireless, adottando reazioni diverse in base al tipo di perdita.

- **Si indichi con chiarezza e precisione in cosa consistono i 3 servizi fondamentali delle reti 5G, ovvero eMBB, URLLC e mMTC. Si indichi quindi in cosa consiste e in che modo la tecnica di Multi Connectivity può aiutare nell'implementazione di tali servizi.**

Le reti 5G sono progettate per rispondere a tre tipologie fondamentali di servizi, ciascuna con requisiti peculiari:

- **Enhanced Mobile Broadband (eMBB):** mira ad aumentare in modo significativo la *capacità di rete* e la velocità di trasmissione dati (fino a decine di Gbit/s). È fondamentale per scenari ad alta richiesta di banda, come realtà aumentata/virtuale, streaming in 4K/8K, eventi di massa e connessioni residenziali a banda ultralarga.
- **Ultra-Reliable and Low Latency Communications (URLLC):** introduce comunicazioni *a bassissima latenza* (circa 1 ms) ed elevatissima affidabilità. Queste caratteristiche sono cruciali per applicazioni mission-critical come veicoli autonomi, automazione industriale, telechirurgia, robotica e controllo remoto.
- **Massive Machine-Type Communications (mMTC):** supporta la *connessione simultanea di un numero enorme di dispositivi IoT*, fino a circa 10^6 device per km². Questi dispositivi trasmettono in genere piccoli volumi di dati ma in modo massivo e continuo, ad esempio in contesti di smart cities, monitoraggio ambientale ed energia intelligente.

Tecnologie abilitanti per il 5G Per realizzare questi servizi, il 5G non si limita a potenziare l'interfaccia radio, ma integra tecniche avanzate:

- **Network Slicing:** la rete fisica viene suddivisa in *slice logici*, ciascuno isolato e configurato per soddisfare requisiti specifici. Ad esempio, un slice eMBB privilegia la banda, un slice URLLC garantisce latenza minima, mentre un slice mMTC è ottimizzato per la gestione massiva di dispositivi IoT.
- **Edge Computing / Mobile Edge Computing (MEC):** porta capacità di calcolo e storage vicino agli utenti, riducendo la distanza tra terminali e servizi. Questo è fondamentale per:

- * eMBB: evitare congestioni centrali posizionando i contenuti multimediali “al bordo” della rete;
 - * URLLC: eseguire elaborazioni localmente per garantire latenza end-to-end minima;
 - * mMTC: processare traffico e segnalazione direttamente all’edge, riducendo il carico sul core network.
- **Multi Connectivity (MC):** consente a un *User Equipment (UE)* di connettersi contemporaneamente a più stazioni base (gNBs). Le connessioni multiple possono essere usate in due modi:
- * *PDCP Split-Bearer*: il traffico viene suddiviso su più leg per aumentare la capacità, soluzione tipica del servizio eMBB;
 - * *PDCP Duplication*: lo stesso pacchetto viene inviato su più connessioni, aumentando l’affidabilità della trasmissione, come richiesto da URLLC.
- Inoltre, in scenari mMTC, la MC migliora copertura e bilanciamento del carico tra celle.
- **Si indichi con chiarezza e precisione in cosa consiste il concetto di Mobile Edge Computing e quali sono i suoi vantaggi (e limiti) all’interno dell’architettura 5G.**

Il **Mobile Edge Computing (MEC)**, o più propriamente *Multi-Access Edge Computing*, è un paradigma architetturale che estende le funzionalità di calcolo e storage dal *core network* verso il *bordo della rete* (edge). L’idea è quella di portare capacità di *cloud computing*, servizi IT e piattaforme applicative in prossimità degli utenti finali, installando risorse di elaborazione presso le stazioni radio base (gNB), i central office o in mini data-center locali.

Obiettivi principali:

- Ridurre la distanza fisica e logica tra utente e applicazioni, **diminuendo di conseguenza la latenza end-to-end.**
- **Gestire in maniera efficiente il traffico, evitando congestioni nel core network centralizzato.**
- **Supportare applicazioni che richiedono risposte in tempo reale o quasi reale.**

~~Vantaggi del MEC nell’architettura 5G:~~

- per garantire e soddisfare i 3 servizi fondamentali
- **Per eMBB:** consente di avvicinare i contenuti multimediali e i servizi di streaming agli utenti, garantendo velocità di download elevate e riducendo il rischio di congestione a livello di backbone.
 - **Per URLLC:** l’elaborazione “in locale” permette di ridurre drasticamente la latenza, requisito indispensabile per applicazioni critiche come guida autonoma, robotica industriale e telemedicina.
 - **Per mMTC:** consente di elaborare e filtrare direttamente all’edge l’enorme mole di segnali provenienti da sensori IoT, riducendo il traffico che deve attraversare la rete core.
 - **Migliora la scalabilità, distribuendo le risorse di calcolo su nodi multipli invece che centralizzarle.**

- Favorisce la creazione di **servizi personalizzati** grazie alla possibilità di integrare applicazioni di terze parti direttamente sull’edge.

Limiti e sfide del MEC:

- **Costo e complessità di implementazione:** richiede la distribuzione capillare di infrastrutture di calcolo e storage presso numerosi nodi di rete.
- **Gestione e orchestrazione:** è necessaria una **coordinazione efficace tra edge, core e cloud** per garantire qualità del servizio (QoS) e continuità nelle connessioni.
- **Sicurezza:** la **maggior distribuzione dei nodi di calcolo aumenta i punti di vulnerabilità** rispetto a un’infrastruttura centralizzata.
- **Limitate risorse locali:** i nodi edge **non dispongono della stessa potenza di elaborazione dei grandi data center cloud**; pertanto sono adatti a compiti distribuiti ma non a calcoli estremamente complessi.

- **Si illustrino con chiarezza e precisione quali sono i principali tipi di protezione nelle reti di telecomunicazione, indicandone per ciascuno vantaggi e svantaggi**

Protezione dedicata (1+1, N:1).

- **Idea:** ad ogni percorso di lavoro (*primary*) si associa un percorso di backup dedicato, con risorse riservate in anticipo. In 1+1 si trasmette in parallelo su entrambi i cammini; in N:1 esistono N backup che sono pronti in caso di guasto per ogni cammino principale.
- **Vantaggi:** massima disponibilità (in assenza di guasti multipli), tempi di ripristino molto rapidi, semplicità di controllo.
- **Svantaggi:** overhead di risorse elevato (ridondanza $\approx 100\%$), efficienza peggiore rispetto alla protezione condivisa.

Protezione condivisa (*Shared Protection* 1:N).

- **Idea:** più percorsi di lavoro proteggono su una *stessa* risorsa di backup, sfruttando il fatto che i guasti non sono simultanei nella maggior parte dei casi.
- **Vantaggi:** maggiore efficienza, minore capacità di backup necessaria.
- **Svantaggi:** disponibilità minore in caso di guasti multipli concorrenti, maggiore complessità di pianificazione e controllo.

Protezione condivisa *priority-aware*.

- **Idea:** estende la protezione condivisa introducendo *classi di servizio* (Gold, Silver, ecc.), in cui le connessioni di classe alta possono preemptare quelle di classe bassa nell’uso del backup.

- **Vantaggi:** differenziazione QoS coerente con gli SLA, maggiore garanzia per le classi prioritarie, efficienza simile alla shared protection.
- **Svantaggi:** degrado per le classi basse in caso di preemption, maggiore complessità di controllo e gestione SLA.

Nota su disponibilità. La disponibilità di un cammino dipende da MTTF e MTTR dei componenti; per un percorso con N elementi,

$$A_{\text{path}} = \prod_{i=1}^N A_i, \quad A_i = \frac{\text{MTTF}}{\text{MTTF} + \text{MTTR}}.$$

La protezione dedicata aumenta l'availability end-to-end, mentre gli schemi condivisi cercano un compromesso tra disponibilità e uso di risorse.

Considerazioni generali.

- La scelta dello schema dipende dal compromesso tra *affidabilità* e *efficienza*: la protezione dedicata massimizza la disponibilità, mentre la protezione condivisa massimizza l'utilizzo delle risorse.
- La disponibilità complessiva di un percorso è funzione dei parametri di affidabilità dei componenti (MTTF e MTTR); protezioni più ridondanti consentono di raggiungere obiettivi di disponibilità più elevati (ad esempio i “5 nove” nelle reti ottiche a lunga distanza).

8 Catena di Markov

$C = \infty$ verificare equilibrio: $\lambda_0 < \mu, \lambda_o = \lambda_S = \lambda_a, \lambda_r = 0$
 $C = K$ sempre in equilibrio, sistema a perdita: $\lambda_a = \lambda_S, P_C, \lambda_r \neq 0$

$N = \infty$ tempi di interarrivo indipendenti dallo stato del sistema
 $N = K$ tempi di interarrivo dipendenti dallo stato del sistema

$\lambda, 1/\mu$ frequenza media arrivi, durata media del servizio
 λ_n, μ_n n stato in cui mi trovo, ossia n utenti, $n \leq C$

Distribuzione	Densità di probabilità (ddp)	Media	Varianza
Poisson	$P(n, t) = \frac{(\lambda t)^n}{n!} e^{-\lambda t}, n = 0, 1, \dots$	λt	λt
Esponenziale negativa	$f(t) = \lambda e^{-\lambda t}, t \geq 0$	$\frac{1}{\lambda}$	$\frac{1}{\lambda^2}$
Erlangiana (ordine n)	$f(x) = \frac{\lambda^n x^{n-1}}{(n-1)!} e^{-\lambda x}, x \geq 0$	$\frac{1}{\lambda}$	$\frac{1}{n\lambda^2}$
Iperesponen. (ordine r)	$f(t) = \sum_{i=1}^r \alpha_i \lambda_i e^{-\lambda_i t}, \sum_{i=1}^r \alpha_i = 1$	$\sum_{i=1}^r \frac{\alpha_i}{\lambda_i}$	$2 \sum_{i=1}^r \frac{\alpha_i}{\lambda_i^2} - \left(\sum_{i=1}^r \frac{\alpha_i}{\lambda_i} \right)^2$

Tabella 1: Distribuzioni con media e varianza

Per definizione abbiamo che: $\rho = \frac{\lambda}{\mu}$
Fattore di utilizzo: $1 - \pi_0$
N° medio utenti/pck nel sistema: $N = \sum_{i=0}^C i \cdot \pi_i$
Teorema di Little: $N = \lambda_a \cdot T$
Tempo attesa sistema: $T = W + \frac{1}{\mu}$
Prob. stazionaria con k utenti: π_k
Prob. di blocco: $\pi_c = \text{prob. essere nello stato } c$
Traffico rifiutato: $\lambda_r = \lambda \cdot \pi_c$
Traffico accettato: $\lambda_a = \lambda - \lambda_r = \lambda \cdot (1 - \pi_c)$
Traffico smaltito: $\lambda_S = \mu(1 - \pi_0) = \lambda_a$

Risultati coda $M|M|1$

Tempo medio di attesa in coda $W = T - \frac{1}{\mu}$
Tempo medio nel sistema $T = \frac{1}{\mu - \lambda}$

Operazioni (procedura generale):

1. **Descrivere il sistema:** stabilire il numero di serventi m , la capacità massima C e i tassi di arrivo λ_k e di servizio μ_k .
2. **Verificare l'equilibrio:**
 - Se $C = \infty$: controllare che $\lambda_0 < \mu$ (condizione di stabilità).
 - Se $C < \infty$: l'equilibrio è garantito (può esserci blocco con probabilità p_C).
3. **Scrivere le equazioni di bilancio:** per ogni stato, la frequenza di ingresso deve essere uguale alla frequenza di uscita. Scrivere le $N - 1$ equazioni più semplici per la risoluzione, scegliendo le superfici adeguate.
4. **Esprimere tutte le probabilità p_k in funzione di p_0 :** usare le equazioni di bilancio per ottenere relazioni ricorsive tra stati.
5. **Determinare p_0 :** applicare la condizione di normalizzazione $\sum p_k = 1$.
6. **Calcolare le grandezze richieste:** fattore di utilizzo, numero medio di utenti N , numero medio in coda N_q , tempi medi T e W_q , probabilità di blocco p_C , ecc.

MM1

MM2

MMm serv. omogenei rate servizio = $\sum_{i=k} \mu_i = k\mu$ nello stato k –esimo

MMm serv. eterogenei stadio 1.1 e 1.2 esistenza utente lento e veloce
rate servizio = $\sum_{i=k} \mu_i = m\mu_1 + \dots + m_k$ nello stato k

ME_k1 erlangiana servizi $\frac{1}{\mu} = \sum_k \frac{1}{k \cdot \mu} = k \cdot \frac{1}{k \cdot \mu}, k\mu$ (tasso singolo)

E_kM1 erlangiana arrivi $\frac{1}{\lambda} = \sum_{i=1}^k \frac{1}{k \cdot \lambda} = k \cdot \frac{1}{k \cdot \lambda}, k\lambda$ (tasso singolo)

Osservazioni:

- Descrivere il sistema inizia che disegno con i tempi, e poi prendo il reciproco ossia i tassi per la catena di Markov.

- Erlangiana arrivi, può essere vista come una macchina che sforna pacchetti a monte di tutto e poi c'è traffico offerto. Inoltre la macchinetta lavora sempre e continua a sfornare degli arrivi anche quando sono dentro il servizio.
- Se il sistema è stabile $\lambda < \mu$, allora raggiunge l'equilibrio ossia uno stato stazionario.
- **i** stato della catena di markov sono i pacchetti/utenti presenti nel sistema (coda + servizio).
- λ **tasso di arrivo**: quante richieste (clienti/pacchetti) arrivano in media per unità di tempo. Gli intervalli tra arrivi sono esponenziali con media $1/\lambda$.
- μ **tasso di servizio (per servente)**: quanto velocemente un servente completa le richieste, in media μ per unità di tempo. Il tempo di servizio è esponenziale con media $1/\mu$. Con k serventi uguali attivi, la velocità totale di uscita è $k\mu$.
- **Tempo al prossimo completamento in $M/M/m$ (omogenei vs eterogenei)**. In stato n sono occupati $k = \min\{n, m\}$ serventi. Se i k serventi sono *omogenei* (stesso tasso μ), il tempo al prossimo completamento è esponenziale con parametro $k\mu$ (cioè media $1/(k\mu)$). Se invece i k serventi sono *eterogenei* con tassi $\mu_1, \dots, \mu_k$, il tempo al prossimo completamento è esponenziale con parametro $\mu_1 + \dots + \mu_k$ (media $1/(\mu_1 + \dots + \mu_k)$). In parole semplici: **quando più serventi lavorano in parallelo, le loro velocità si sommano**.

k serventi omogenei $T = \min\{T_i\} = \exp(k \cdot \mu)$ $i = \text{pck}$

k serventi eterogenei $T = \min\{T_i\} = \exp\left(\sum_i^k \mu_i\right)$ $i = \text{utenti}$

- C è la notazione di Kendall e indicata i posti in coda, mentre c è la capacità del sistema, ossia coda + servizio.
- L'ultimo stato della catena di Markov è $c = \text{coda} + \text{servizio}$

9 Grado di Servizio

- Trasformare tutto in pck/s
- Per **instradamento non suddiviso** (a volte detto anche instradamento a flusso non frazionato) si intende che tutto il flusso di traffico deve essere instradato interamente su un solo cammino, senza poterlo suddividere in parti e distribuire su più collegamenti contemporaneamente.
- Nelle reti di Jackson ogni coda si può modellare come un sistema $M|M|1$ indipendente
- **Osservazione importante**: si assume che i tempi di servizio siano indipendenti da nodo a nodo. In realtà, un pacchetto “lungo” in uscita da una coda tenderà ad

avere un tempo di servizio “lungo” anche nella coda successiva. Tuttavia, se molti flussi indipendenti si mescolano all'ingresso di una coda, la somma dei traffici diventa sufficientemente casuale da soddisfare l'ipotesi di indipendenza. Questa approssimazione è nota come **Kleinrock independence approximation**.

- **Teorema di Burke**: in un sistema $M|M|1$, $M|M|m$ o $M|M|\infty$, con qualunque disciplina di coda e in regime stazionario, se il tasso medio degli arrivi è λ , allora:

Il processo in uscita è ancora di Poisson con tasso medio λ .

10 Generazione Numeri Casuali

Per **sintesi di una variabile aleatoria** si intende la costruzione (o simulazione) di realizzazioni di una variabile casuale X con una certa distribuzione assegnata, a partire da numeri pseudo-casuali uniformi in $(0, 1)$. Mentre l'analisi statistica parte dai dati per stimarne le proprietà, la sintesi procede in senso inverso: dati i parametri della distribuzione, si generano campioni che la seguono.

Per sintetizzare una variabile aleatoria X a partire da numeri pseudo-casuali uniformi in $(0, 1)$, si procede come segue:

- **Identificare la distribuzione di X** : individuare la PDF $f_X(x)$ o la CDF $F_X(x)$ e il dominio dei valori x .
- **Se nota solo la PDF**: calcolare la CDF

$$F_X(x) = \int_{-\infty}^x f_X(t) dt.$$

- **Metodo del percentile**: poniamo

$$U \sim \mathcal{U}(0, 1), \quad U = F_X(X).$$

Per il teorema del *Probability Integral Transform* (teorema fondamentale delle funzioni di variabili aleatorie con trasformazioni CDF), U è uniforme.

- **Invertire la CDF**: dato un generatore di numeri uniformi U , calcolare direttamente

$$X = F_X^{-1}(U),$$

che fornisce una realizzazione di X con distribuzione desiderata.

- **Nota utile**: poiché $U \sim \mathcal{U}(0, 1)$ implica anche $1-U \sim \mathcal{U}(0, 1)$, si può usare questa proprietà per semplificare eventuali espressioni (ad esempio nell'esponenziale).

10.1 Trasformazioni di una variabile uniforme

Sia $U \sim \mathcal{U}(0, 1)$. Una proprietà fondamentale è che, dati due numeri reali $a < b$, la variabile

$$Y = a + (b - a)U$$

è uniformemente distribuita su $[a, b]$, cioè

$$Y \sim \mathcal{U}(a, b).$$

Esempi

- $Y = -U \Rightarrow Y \sim \mathcal{U}(-1, 0)$ (caso $a = -1, b = 0$).
- $Y = -2 + 5U \Rightarrow Y \sim \mathcal{U}(-2, 3)$ (caso $a = -2, b = 3$).
- $Y = 3 + U \Rightarrow Y \sim \mathcal{U}(3, 4)$ (caso $a = 3, b = 4$).
- $Y = 2U - 1 \Rightarrow Y \sim \mathcal{U}(-1, 1)$ (caso $a = -1, b = 1$).

Nota importante Quando definiamo, ad esempio, $Y = -U$, **non stiamo moltiplicando la pdf per -1** . La pdf (funzione di densità di probabilità) descrive come è distribuita la massa di probabilità sui valori possibili, non viene moltiplicata o cambiata di segno. Quello che avviene realmente è una *trasformazione dei valori della variabile casuale*: U può assumere valori nell’intervallo $[0, 1]$ con densità costante, e applicando la trasformazione $y = -u$ questi valori vengono riflessi nell’intervallo $[-1, 0]$. La distribuzione resta uniforme, ma il supporto (cioè l’insieme dei valori possibili) cambia da $[0, 1]$ a $[-1, 0]$.

10.2 Sintesi di una uniforme su supporto disconnesso

Vogliamo sintetizzare X con densità costante $f_X(x) = \frac{1}{10}$ sul supporto disconnesso

$$[-5, 0] \cup [2, 7],$$

di ampiezza totale $5 + 5 = 10$ (quindi la densità è $1/10$ su ciascun intervallo).

Idea (mixture + inversione CDF). La CDF di X è pezzo-per-pezzo lineare con un salto piatto (nessuna massa) in $(0, 2)$:

$$F_X(x) = \begin{cases} 0, & x < -5, \\ \frac{x+5}{10}, & -5 \leq x \leq 0, \\ \frac{1}{2}, & 0 < x < 2, \\ \frac{1}{2} + \frac{x-2}{10}, & 2 \leq x \leq 7, \\ 1, & x > 7. \end{cases}$$

Dato $U \sim \mathcal{U}(0, 1)$, imponiamo $U = F_X(X)$ e invertiamo per ottenere $X = F_X^{-1}(U)$.

Procedimento operativo.

1. Genera $U \sim \mathcal{U}(0, 1)$.
2. Se $0 \leq U \leq \frac{1}{2}$, poni
3. Se $\frac{1}{2} < U \leq 1$, poni

$$X = 10U - 5 \in [-5, 0].$$

$$X = 10U - 3 \in [2, 7].$$

Perché funziona.

- La mappa $U \mapsto 10U - 5$ invia uniformemente $[0, \frac{1}{2}]$ su $[-5, 0]$, con densità $(1/\frac{1}{2}) \cdot (1/10) = 1/10$.
- La mappa $U \mapsto 10U - 3$ invia uniformemente $[\frac{1}{2}, 1]$ su $[2, 7]$, con la stessa densità $1/10$.
- Il “buco” $(0, 2)$ nasce perché $U \in (0.5, 0.5)$ non è mai selezionato: passando da $U = \frac{1}{2}$ si salta da $X = 0$ a $X = 2$, come desiderato.

Forma compatta.

$$\begin{cases} X = 10U - 5, & U \leq \frac{1}{2}, \\ X = 10U - 3, & \text{altrimenti.} \end{cases}$$

10.3 Altre operazioni

Equazione della retta:

$$\begin{aligned} y - y_0 &= m \cdot (x - x_0) \quad \text{Per un punto } P_0 \\ y &= m \cdot x + q \\ m &= \frac{y_2 - y_1}{x_2 - x_1} \end{aligned}$$

Definire incognita h :

$$\int_{x_1}^{x_2} f_1(x) dx + \int_{x_3}^{x_4} f_2(x) dx = 1$$

Definire $P(X) \leq 1$:

$$P(X \leq 1) = \int_{x_1}^1 f_1(x) dx$$

Metodo del percentile:

$$F_X(x) = \begin{cases} 0 & \text{quando } x \in (-\infty, -5) \\ \int_{-5}^x \frac{1}{24} dx = \frac{1}{24}x + \frac{5}{24} & \text{quando } x \in [-5, -3) \\ \frac{1}{6} + \int_{-3}^x \frac{1}{24} dx = \frac{1}{24}x + \frac{9}{24} & \text{quando } x \in [-3, \frac{1}{2}) \\ \frac{1}{6} + \int_{-3}^{1/2} \frac{1}{24} dx = \frac{19}{48} & \text{quando } x \in [\frac{1}{2}, \frac{3}{2}) \\ \frac{19}{48} + \int_{3/2}^x \frac{1}{24} dx = \frac{1}{24}x + \frac{1}{3} & \text{quando } x \in [\frac{3}{2}, 4) \\ \frac{1}{2} & \text{quando } x \in [4, 5) \\ 1 & \text{quando } x \in [5, +\infty) \end{cases} \quad X = F_X^{-1}(U) = \begin{cases} 24U - 5 & \text{quando } U \in (0, \frac{1}{12}] \\ -3 & \text{quando } U \in (\frac{1}{12}, \frac{3}{12}] \\ 24U - 9 & \text{quando } U \in (\frac{3}{12}, \frac{19}{48}] \\ 24U - 8 & \text{quando } U \in (\frac{19}{48}, \frac{1}{2}] \\ 5 & \text{quando } U \in (\frac{1}{2}, 1] \end{cases}$$

$$F_X(-3) = \frac{1}{24}(-3) + \frac{5}{24} = \frac{1}{6}$$

$$F_X(x) = F_X(-3) + \int_{-5}^x \frac{1}{24} dx$$

Sintesi di una gaussiana $\mathbf{X}$:

$$X = \mu + \sigma \cdot Z \quad Z \sim \mathcal{N}(0, 1)$$

$$\text{Box Muller: } Z = \sqrt{-2 \ln U_1} \cdot \cos(2\pi U_2) \quad U_1, U_2 \sim \mathcal{U}(0, 1)$$

Sintesi altre ditribuzioni:

$$\textbf{Esponenziale: } f_X(x) = \lambda \cdot e^{-\lambda x} \quad \mathbb{E}[X] = \frac{1}{\lambda} < \infty$$

$$\textbf{Esponenziale: } f_X(x) = \frac{1}{\lambda} \cdot e^{-x/\lambda} \quad \mathbb{E}[X] = \lambda > 0$$

$$\textbf{Rayleigh: } f_X(x) = x \cdot e^{-x^2/2}$$

11 Prestazioni sorgenti TCP canali wireless

Throughput. Quantità totale di bit al secondo che passano sul canale, inclusi gli overhead di protocollo (intestazioni TCP/IP, ritrasmissioni, ACK, ecc.).

Goodput. Quantità di bit al secondo realmente consegnati all'applicazione, cioè dati *utili*, senza considerare gli overhead di protocollo e le eventuali ritrasmissioni.

$$\text{Goodput} = \frac{MSS}{RTT} \cdot \frac{C}{\sqrt{p}}$$

dove:

- $MSS = \text{Maximum Segment Size}$, cioè la dimensione massima dei dati utili per segmento TCP.
- $RTT = \text{Round Trip Time}$, il tempo di andata e ritorno della connessione.
- p = probabilità di perdita di un pacchetto.
- C = costante derivata dal modello, che dipende anche dalle politiche di ACK adottate.

No delayerd ACKS:	$\sqrt{\frac{3}{2}}$
Delayerd ACKS:	$\sqrt{\frac{3}{4}}$